

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Tuấn Công - Trần Văn Anh Thư

XÂY DỰNG MÔ HÌNH DỰ ĐOÁN MỨC
ĐỘ THU HÚT CỦA VIDEO TRÊN
MẠNG XÃ HỘI SỬ DỤNG KỸ THUẬT
CHẮT LỌC TRI THỨC

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

Tp. Hồ Chí Minh, tháng 07/2026

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Nguyễn Tuấn Công - 22120039

Trần Văn Anh Thư - 22120357

**XÂY DỰNG MÔ HÌNH DỰ ĐOÁN MỨC
ĐỘ THU HÚT CỦA VIDEO TRÊN
MẠNG XÃ HỘI SỬ DỤNG KỸ THUẬT
CHẮT LỌC TRI THỨC**

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CHUẨN

GIẢNG VIÊN HƯỚNG DẪN

TS. Lê Thanh Tùng

ThS. Văn Chí Nam

Tp. Hồ Chí Minh, tháng 07/2026

Lời cam đoan

Dưới sự hướng dẫn tận tình của thầy Lê Thanh Tùng và thầy Văn Chí Nam, nhóm chúng tôi đã tiến hành thực hiện đề tài này một cách nghiêm túc và có trách nhiệm. Công trình này là kết quả của quá trình tự nghiên cứu, tìm hiểu tài liệu, phân tích và thực nghiệm của chính nhóm, không sao chép hay dựa vào bất kỳ sản phẩm nghiên cứu nào khác. Trong phần nội dung lý thuyết, nhóm có sử dụng một số nguồn tài liệu tham khảo và đã ghi rõ trong danh mục tài liệu cuối luận văn. Các số liệu và kết quả thu được trong quá trình thực hiện đều đảm bảo tính trung thực và độc lập, không trùng lặp cũng như có hình thức làm giả nào. ...

Thuyết minh chỉnh sửa đề tài

Bản thuyết minh chỉnh sửa đề tài (nếu có thay đổi tên đề tài, nội dung báo cáo, ... trong cuốn báo cáo sau bảo vệ)

Nhận xét hướng dẫn

Bản nhận xét của giảng viên hướng dẫn (có chữ ký) do giáo vụ cung cấp.

Nhận xét phản biện

Bản nhận xét của giảng viên phản biện (có chữ ký) do giáo vụ cung cấp.

Lời cảm ơn

Lời đầu tiên, chúng em xin gửi lời cảm ơn chân thành đến TS. Lê Thanh Tùng và ThS. Văn Chí Nam – hai thầy đã đồng hành, hướng dẫn và hỗ trợ nhóm trong suốt quá trình thực hiện khóa luận. Với sự tận tâm và tinh thần trách nhiệm cao, hai thầy đã cùng góp ý, định hướng nội dung và giúp nhóm điều chỉnh cách tiếp cận phù hợp hơn với mục tiêu nghiên cứu. Những nhận xét và phản hồi từ hai thầy không chỉ giúp nhóm hoàn thiện khóa luận về mặt nội dung và phương pháp mà còn góp phần nâng cao tư duy phân tích và cách trình bày kết quả một cách rõ ràng, logic hơn. Sự đồng hành của hai thầy là một phần quan trọng giúp nhóm giữ vững định hướng và hoàn thành công việc đúng tiến độ.

Chúng em cũng xin gửi lời cảm ơn đến Khoa Công nghệ Thông tin và các thầy cô giảng viên trong khoa, Trường Đại học Khoa học Tự nhiên – ĐHQG TP.HCM, đã tạo điều kiện học tập thuận lợi, cung cấp kiến thức nền tảng và hỗ trợ nhóm trong suốt quá trình học tập và nghiên cứu.

Chúng em xin chân thành cảm ơn.

Đề cương chi tiết

Bản đề cương đã thực hiện và nộp cho giáo vụ trước đó (*phải có chữ ký của giảng viên hướng dẫn*).

Mục lục

Thuyết minh chỉnh sửa đề tài	ii
Nhận xét của GV hướng dẫn	iii
Nhận xét của GV phản biện	iv
Lời cảm ơn	v
Đề cương	vi
Mục lục	vii
Danh sách hình	xiii
Danh sách bảng	xiv
Tóm tắt	xiv
1 Giới thiệu	1
1.1 Giới thiệu bài toán dự đoán mức độ thu hút của video trên mạng xã hội	1
1.2 Giới thiệu chỉ số tương tác ECR (Engagement Continuation Rate)	2
1.3 Các hướng giải quyết hiện tại cho bài toán dự đoán tương tác video	2
1.4 Động lực nghiên cứu	4

1.5	Mô hình đề xuất và đóng góp đề tài	4
1.5.1	Cách thức hoạt động của SnapUGC-LightKD . . .	5
1.5.2	Điểm đổi mới của đề tài	5
1.5.3	Đánh giá hiệu quả của SnapUGC-LightKD	6
1.5.4	Đóng góp của đề tài	6
2	Các công trình nghiên cứu liên quan	7
2.1	Dự đoán tương tác và chất lượng video UGC ngắn	7
2.1.1	Từ đánh giá chất lượng video đến dự đoán tương tác	7
2.1.2	Đặc thù của chỉ số ECR	8
2.1.3	Các hệ thống Teacher đa phương thức	9
2.2	Học biểu diễn đa phương thức trong video	9
2.2.1	Các hướng fusion đa phương thức	9
2.2.2	Vai trò của văn bản metadata	10
2.2.3	Hạn chế của đặc trưng thủ công	10
2.3	Chất lọc tri thức cho mô hình đa phương thức	11
2.3.1	Từ KD đầu ra đến KD biểu diễn	11
2.3.2	Chất lọc trong bài toán hồi quy và xếp hạng	11
2.4	LUPI và học từ thông tin đặc quyền	12
2.5	Kết luận khảo sát và định vị SnapUGC-LightKD	12
3	Các công trình nền tảng	14
3.1	Kiến trúc Transformer và Cơ chế Tự chú ý	14
3.1.1	Động lực ra đời	15
3.1.2	Biểu diễn token và positional encoding	15
3.1.3	Scaled Dot-Product Attention	16
3.1.4	Multi-Head Attention	18
3.1.5	Khối Transformer encoder	19
3.1.6	Vai trò trong SnapUGC-LightKD	19
3.2	Giao diện đặc trưng đa phương thức và artifact Teacher . .	21
3.2.1	Tổng quan giao diện Teacher–Student	21
3.2.2	Các backbone Teacher được xem như nguồn artifact	23

3.2.3	Nguyên tắc chọn nội dung nền tảng	24
3.3	Lý thuyết Chắt lọc Tri thức	24
3.3.1	Hinton KD và softmax với nhiệt độ	24
3.3.2	KL-Divergence trong chắt lọc	25
3.3.3	Chắt lọc cho bài toán hồi quy ECR	26
3.3.4	FitNets và chắt lọc đặc trưng ẩn	26
3.3.5	Attention Transfer	27
3.3.6	Relational KD và cấu trúc thứ hạng	27
3.3.7	LUPI và mạng ảo ảnh	28
3.4	Phân tích độ phức tạp và ý nghĩa thiết kế đối với mô hình nhẹ	28
3.4.1	Độ phức tạp của Self-Attention	29
3.4.2	Độ phức tạp của backbone video	29
3.4.3	Độ phức tạp của mô hình caption và text encoder lớn	30
3.4.4	Nguyên tắc thiết kế rút ra	30
3.5	Liên hệ giữa các nền tảng và thiết kế SnapUGC-LightKD	31
3.5.1	Tổng kết chương	31
4	Phương pháp đề xuất	34
4.1	Tổng quan thiết kế hệ thống	34
4.2	Ký hiệu và dữ liệu đầu vào	35
4.3	Teacher tham chiếu và quá trình sinh artifact	37
4.4	Kiến trúc Student deployable	39
4.4.1	Luồng video temporal Transformer	39
4.4.2	Luồng văn bản và Source-specific text embedding	40
4.4.3	Fusion MLP và đầu dự đoán	41
4.5	Mạng ảo ảnh dựa trên LUPI	42
4.5.1	Động lực thiết kế	42
4.5.2	Kiến trúc AdvancedHallucinationHead	43
4.6	Hệ thống hàm mất mát đa nhiệm	44
4.6.1	Loss nhãn cứng	44

4.6.2	Loss ECR mềm từ Teacher	45
4.6.3	Loss ECR theo clip	45
4.6.4	Loss attention theo thời gian	45
4.6.5	Loss căn chỉnh hidden state	46
4.6.6	Loss quan hệ mẫu RKD	46
4.6.7	Loss hallucination đặc quyền	47
4.6.8	Tổng loss	47
4.7	Chiến lược huấn luyện đa giai đoạn	47
4.8	Phân tích độ phức tạp và triển khai hệ thống	50
4.8.1	Tổ chức artifact và tính tái lập	51
4.9	Ổn định tối ưu và cân bằng gradient	51
4.9.1	Vai trò của AdamW và weight decay	52
4.10	Pseudocode suy luận triển khai	52
4.11	Suy luận triển khai	53
4.12	Tổng kết chương	54
5	Thực nghiệm và kết quả	55
5.1	Tập dữ liệu và giao thức đánh giá	55
5.1.1	Tập dữ liệu SnapUGC	55
5.1.2	Giao thức chia dữ liệu	56
5.2	Độ đo đánh giá	57
5.3	Thiết lập thực nghiệm	57
5.3.1	Artifact của Teacher	57
5.3.2	Cấu hình Student chính	58
5.4	Kết quả thực nghiệm chính	59
5.5	Nghiên cứu lược bỏ thành phần	60
5.6	Phân tích chẩn đoán và giới hạn thông tin đầu vào	61
5.6.1	Khoảng cách giữa Student có thể triển khai và upper-bound compressed Student	61
5.6.2	Vì sao tăng dung lượng Student lên 1.5M tham số làm giảm điểm	62

5.6.3	Bảng chẩn đoán đặc trưng đầu vào	63
5.6.4	Lỗi nguyên đa chiều và nhiễu đặc trưng thô	63
5.7	Phân tích định tính và nghiên cứu tình huống	64
5.7.1	Trường hợp 1: Video chuyển động mạnh nhưng thiếu đặc trưng hành động	64
5.7.2	Trường hợp 2: Video clickbait nhưng Teacher làm mượt nhiễu	65
5.7.3	Trường hợp 3: Video có âm thanh/ngữ cảnh quan trọng	65
5.8	Phân tích thống kê bổ sung	67
5.8.1	Diễn giải đồng thời PLCC và SRCC	67
5.8.2	Sai số theo vùng nhãn	67
5.8.3	Phân loại lỗi thường gặp	68
5.9	Độ tin cậy và giới hạn của thực nghiệm	68
5.9.1	Giới hạn do kích thước tập dữ liệu	68
5.9.2	Giới hạn do Teacher artifact	69
5.9.3	Giới hạn của nghiên cứu tình huống giả định	69
5.10	Hàm ý thực tiễn cho triển khai	69
5.11	Độ nhạy siêu tham số và khuyến nghị tái lập	70
5.11.1	Độ nhạy của trọng số KD	70
5.11.2	Độ nhạy của dropout và weight decay	71
5.11.3	Độ nhạy của số tầng Transformer	71
5.12	Kịch bản triển khai thực tế	72
5.12.1	Triển khai offline trong hệ thống kiểm duyệt nội dung	72
5.12.2	Triển khai gần thời gian thực trên thiết bị biên	73
5.12.3	Triển khai như mô hình sàng lọc trước Teacher	73
5.13	Khuyến nghị cho các thí nghiệm tiếp theo	74
5.14	Thảo luận tổng hợp	74
5.15	Tổng kết chương	75

6	Kết luận và hướng phát triển	76
6.1	Tóm tắt đóng góp của đề tài	76
6.2	Hạn chế của đề xuất	77
6.3	Hướng phát triển tương lai	77
	Tài liệu tham khảo	79

Danh sách hình

3.1	Khối Transformer encoder dùng để mô hình hóa quan hệ giữa các token hoặc clip.	20
4.1	Tổng quan SnapUGC-LightKD: Teacher chỉ tham gia trong huấn luyện, Student được giữ lại khi suy luận.	35
4.2	Kiến trúc Teacher SnapUGC đa phương thức	37
4.3	Kiến trúc Student deployable của SnapUGC-LightKD. Với v35, $d_{in} = 1024$ và $d_s = 96$; với cấu hình tốt nhất, đầu vào video có thể gồm <code>frame_fusion</code> , Lite Action và CLIP. Các nhánh KD nét đứt chỉ dùng trong huấn luyện.	42
4.4	Mạng ảo ảnh học tái tạo đặc trưng đặc quyền của Teacher từ hidden state của Student.	44
5.1	Một số khung hình mẫu trong tập dữ liệu SnapUGC	56

Danh sách bảng

3.1	Các nhóm artifact đa phương thức trong SnapUGC-LightKD	22
3.2	Liên hệ nền tảng và SnapUGC-LightKD	32
4.1	Ký hiệu chính trong phương pháp SnapUGC-LightKD . .	36
4.2	Các artifact Teacher được xuất trong triển khai thực nghiệm	38
4.3	Ý nghĩa của các trọng số trong hàm mất mát đa nhiệm . .	48
5.1	Cấu hình thực nghiệm chính của SnapUGC-LightKD tốt nhất	58
5.2	Kết quả chính trên split kiểm định 1.000 video SnapUGC .	59
5.3	Ablation study của các nhóm mất mát chất lọc	60
5.4	Hiệu suất của các mốc chẩn đoán và cấu hình có thể triển khai tốt nhất	63
5.5	Tóm tắt ba nghiên cứu tình huống định tính	66
5.6	Phân loại lỗi định tính trong dự đoán ECR	68
5.7	Khuyến nghị điều chỉnh siêu tham số dựa trên phân tích thực nghiệm	72

Tóm tắt

Trong những năm gần đây, sự bùng nổ của video ngắn trên các mạng xã hội tạo nên nhu cầu cấp thiết về dự đoán mức độ thu hút (engagement) của người xem. Tuy nhiên, việc dự đoán bằng mô hình đa phương thức lớn gặp rào cản lớn về chi phí tính toán khi triển khai trên thiết bị cạnh (edge devices). Đề tài này giải quyết thách thức trên bằng cách xây dựng hệ thống SnapUGC-LightKD – một mô hình Student gọn nhẹ dự đoán tỷ lệ tiếp tục tương tác (Engagement Continuation Rate – ECR) của video ngắn thông qua kỹ thuật chắt lọc tri thức (Knowledge Distillation).

Giải pháp đề xuất tận dụng tri thức từ Teacher SnapUGC đa phương thức, bao gồm các tín hiệu ECR mềm, ECR theo clip, hidden state, attention theo thời gian và đặc trưng đặc quyền như action/caption feature. Student triển khai được sử dụng giao diện đầu vào rẻ hơn Teacher, gồm `frame_fusion_feature`, embedding nhãn âm thanh, tiêu đề, mô tả, đồng thời bổ sung CLIP keyframe feature và Lite Action ở cấu hình tốt nhất. Trên split 5.000 video SnapUGC, SnapUGC-LightKD Edge Ensemble đạt PLCC 0.6372, SRCC 0.6302 và Final Score 0.6330, cải thiện +0.0737 so với baseline Student mở rộng (0.5593). Cấu hình diagnostic v35 đạt 0.6027, còn cấu hình upper-bound dùng token nén từ Teacher đạt 0.6947, gần với Teacher tham chiếu 0.7038. Kết quả này chứng minh tính khả thi của chắt lọc tri thức đa tầng cho bài toán hồi quy ECR đa phương thức, đồng thời chỉ ra hướng phát triển tiếp theo là xây dựng các bộ trích xuất đặc trưng biên giàu thông tin hơn nhưng vẫn đủ nhẹ cho suy luận thực tế.

Chương 1

Giới thiệu

1.1 Giới thiệu bài toán dự đoán mức độ thu hút của video trên mạng xã hội

Trong những năm gần đây, sự bùng nổ của các nền tảng chia sẻ video ngắn như TikTok, Instagram Reels, hay YouTube Shorts đã thay đổi hoàn toàn cách thức tiếp nhận thông tin và giải trí của người dùng toàn cầu. Video ngắn đã trở thành dạng nội dung phổ biến nhất và có tốc độ lan tỏa mạnh mẽ nhất trên không gian số. Đối với các nhà sáng tạo nội dung, doanh nghiệp tiếp thị, và các nhà vận hành nền tảng, việc ước lượng và dự đoán chính xác mức độ thu hút (engagement prediction) của một video trước khi phát hành đóng vai trò vô cùng quan trọng. Nó giúp các nhà phát triển nội dung tối ưu hóa chất lượng kịch bản, hỗ trợ các doanh nghiệp lên kế hoạch phân phối hiệu quả và giảm thiểu rủi ro chi phí sản xuất. Tuy nhiên, mức độ tương tác của một video trong thực tế không chỉ phụ thuộc vào các yếu tố nội tại (hình ảnh, âm thanh, văn bản tiêu đề/mô tả) mà còn bị chi phối mạnh mẽ bởi các yếu tố phi nội dung phức tạp bên ngoài như thuật toán phân phối của nền tảng, độ nổi tiếng của tài khoản, thời điểm đăng tải, và xu hướng biến động của xã hội. Do đó, việc xây dựng mô hình dự đoán mức độ thu hút tương đối dựa trên tín hiệu nội dung đa phương thức nội tại của video là hướng tiếp cận có tính thực tiễn cao, giúp

đưa ra những đánh giá khách quan nhất về giá trị truyền tải của chính bản thân video đó.

1.2 Giới thiệu chỉ số tương tác ECR (Engagement Continuation Rate)

Để cụ thể hóa mức độ thu hút của video ngắn, các chỉ số đo lường truyền thống như số lượt xem (views), lượt thích (likes), hay lượt chia sẻ (shares) thường được sử dụng rộng rãi. Tuy nhiên, các nghiên cứu gần đây chỉ ra rằng các chỉ số này chứa lượng nhiễu rất lớn, dễ bị thao túng bởi các kỹ thuật giật tít câu khách (clickbait) và không phản ánh trung thực khả năng duy trì sự chú ý của người xem. Hơn nữa, điểm số đánh giá chất lượng video truyền thống (Mean Opinion Score - MOS) chỉ tập trung vào khía cạnh kỹ thuật hiển thị chứ không tương quan mạnh mẽ với hành vi tương tác thực tế của người dùng. Nhằm khắc phục những hạn chế này, chỉ số ECR (Engagement Continuation Rate - Tỷ lệ tiếp tục tương tác) được đề xuất như một thang đo chuẩn hóa vượt trội. ECR đo lường tỷ lệ người xem tiếp tục theo dõi video tại mỗi mốc thời gian, phản ánh trực tiếp khả năng giữ chân (retention) và mức độ hấp dẫn của nội dung theo tiến trình thời gian. Khoá luận này tập trung nghiên cứu bài toán hồi quy dự đoán ECR trong khoảng $[0, 1]$ từ dữ liệu đa phương thức trên bộ dữ liệu SnapUGC [1] - một tập hợp các video ngắn tự nhiên do người dùng tạo ra (User-Generated Content), phản ánh chân thực các hành vi tương tác tự nhiên trên các nền tảng mạng xã hội lớn hiện nay.

1.3 Các hướng giải quyết hiện tại cho bài toán dự đoán tương tác video

Hiện nay, các nghiên cứu giải quyết bài toán dự đoán tương tác hoặc đánh giá chất lượng video ngắn thường được chia thành ba hướng tiếp cận chính:

- **Phương pháp truyền thống sử dụng đặc trưng thủ công (hand-crafted features):** Kết hợp các đặc trưng cơ bản về thị giác (độ sáng, độ bão hòa, độ tương phản) hoặc thính giác (tần số âm thanh, nhiễu) với các thuật toán học máy cổ điển như Support Vector Regression (SVR) hay Random Forest. Hướng tiếp cận này đơn giản, chi phí tính toán thấp nhưng gặp giới hạn lớn khi biểu diễn các thông tin ngữ nghĩa mức cao và sự tương tác phức tạp giữa các modality khác nhau.
- **Mô hình học sâu đa phương thức quy mô lớn:** Tận dụng sức mạnh của các mô hình tiền huấn luyện khổng lồ để trích xuất đặc trưng ngữ nghĩa từ nhiều nguồn thông tin khác nhau. Tiêu biểu là mô hình EVQA (Engagement Video Quality Assessment) đạt độ chính xác rất cao nhờ tích hợp đa luồng thông tin (EfficientNetV2-S cho semantic, UVQ cho chất lượng thị giác, ResNet3D-18 cho hành động, mPLUG-2 cho caption, YAMNet cho audio và Stable Diffusion cho text encoder). Tuy nhiên, các mô hình này cực kỳ nặng (hơn 1.8 tỷ tham số) và yêu cầu tài nguyên phần cứng lớn, khiến việc triển khai trực tiếp trên các thiết bị di động của người dùng hay suy luận thời gian thực là bất khả thi.
- **Kỹ thuật chất lọc tri thức (Knowledge Distillation - KD):** Đây là hướng đi tiềm năng cho phép chuyển giao tri thức từ một mô hình lớn (Teacher) sang một mô hình gọn nhẹ (Student) [2]. Bằng cách học hỏi từ cả nhãn thực tế và các tín hiệu giám sát phụ (soft targets, hidden states, attention maps) từ Teacher, mô hình Student có thể duy trì được hiệu suất dự đoán tốt trong khi giảm thiểu tối đa chi phí tính toán và bộ nhớ.

1.4 Động lực nghiên cứu

Mặc dù các mô hình đa phương thức lớn (Teacher) mang lại hiệu quả dự đoán ECR vượt trội, rào cản về kích thước và tốc độ suy luận khiến chúng không thể triển khai trực tiếp trên các thiết bị di động có tài nguyên hạn chế. Ngược lại, nếu thiết kế một mô hình Student gọn nhẹ thông thường chỉ huấn luyện trực tiếp trên nhãn ECR (hard targets), mô hình sẽ dễ bị quá khớp (overfitting) và không thể học được các mối quan hệ ngữ nghĩa đa phương thức phức tạp do thiếu thông tin giám sát và dung lượng biểu diễn hạn chế. Điều này tạo nên một **khoảng trống thông tin** (information bottleneck) giữa dữ liệu đầu vào đơn giản và độ phức tạp của nhãn ECR. Động lực chính của khóa luận này là nghiên cứu và xây dựng một giải pháp chất lọc tri thức đa nhiệm vụ hiệu quả, giúp chuyển giao tối đa tri thức đa phương thức từ mô hình Teacher khổng lồ sang một mô hình Student siêu nhẹ mà không làm thay đổi kiến trúc hoặc tăng chi phí tính toán của Student khi chạy thực tế (inference). Qua đó, đề tài hướng đến việc giải quyết bài toán trade-off giữa độ chính xác dự đoán và hiệu năng thực thi của các mô hình học sâu đa phương thức trên thiết bị cạnh.

1.5 Mô hình đề xuất và đóng góp đề tài

Dựa trên động lực đó, chúng tôi giới thiệu **SnapUGC-LightKD** (Lightweight Knowledge Distillation for Social Media Video Engagement Prediction), một phương pháp chất lọc tri thức đa tầng nhằm tận dụng sức mạnh của hệ thống Teacher SnapUGC đa phương thức để cải thiện hiệu suất dự đoán của mô hình Student gọn nhẹ. Cấu hình Student chính trong luận văn sử dụng khoảng **383 nghìn tham số** cho phần mô hình dự đoán và chỉ nhận các artifact triển khai được gồm đặc trưng video `frame_fusion_feature` cùng embedding nhãn âm thanh, tiêu đề và mô tả.

1.5.1 Cách thức hoạt động của SnapUGC-LightKD

SnapUGC-LightKD sử dụng phương pháp huấn luyện đa nhiệm kết hợp chất lọc tri thức đa tầng. Mô hình Student được huấn luyện để đồng thời tối ưu hóa các hàm mất mát chất lọc tri thức tiên tiến:

- **Chất lọc Logit & Soft Targets** [2]: Truyền tải điểm ECR mềm từ Teacher sang Student, giúp làm mượt nhiễu của nhãn thực tế.
- **Căn chỉnh đặc trưng FitNets** [3]: Sử dụng đầu chiếu để khớp các vector trạng thái ẩn của Student vào không gian biểu diễn lớn của Teacher thông qua hàm mất mát cosine.
- **Chất lọc chú ý (Attention Transfer - AT)** [4]: Ép phân phối chú ý theo thời gian của Student mô phỏng theo Teacher thông qua KL Divergence.
- **Chất lọc quan hệ mẫu (Relational KD - RKD)** [5]: Ràng buộc cấu trúc thứ hạng tương đối giữa các video trong cùng batch.
- **Chất lọc theo danh sách và tương quan**: Tối ưu thêm các tín hiệu teacher Pearson, teacher Spearman và listwise ranking để phù hợp với thước đo Final Score.

1.5.2 Điểm đổi mới của đề tài

Điểm nổi bật của SnapUGC-LightKD là việc kết hợp giao diện đầu vào triển khai được với các tín hiệu đặc quyền chỉ dùng trong huấn luyện. Student được học từ hidden state, attention, clip-level ECR và các đặc trưng giàu thông tin của Teacher, nhưng khi suy luận chỉ cần luồng video/text rút gọn. Ngoài ra, Student sử dụng source-specific text embedding để phân biệt nhãn âm thanh, tiêu đề và mô tả, giúp quá trình hợp nhất đa phương thức ổn định hơn so với việc gộp các token văn bản ẩn danh.

1.5.3 Đánh giá hiệu quả của SnapUGC-LightKD

Để kiểm chứng tính hiệu quả, SnapUGC-LightKD được thử nghiệm trên bộ dữ liệu SnapUGC 5.000 video, chia cố định thành 4.000 video huấn luyện và 1.000 video kiểm định. Quá trình đánh giá dựa trên hệ số tương quan tuyến tính Pearson (PLCC), hệ số tương quan thứ hạng Spearman (SRCC) và Final Score $0.6 \times \text{SRCC} + 0.4 \times \text{PLCC}$. Hiệu suất của đề xuất được so sánh với baseline Student không chất lọc, Teacher tham chiếu và upper-bound Student dùng token nén từ Teacher.

1.5.4 Đóng góp của đề tài

Các đóng góp chính của đề tài khóa luận có thể được tóm tắt như sau:

- **Đề xuất hệ thống SnapUGC-LightKD:** Xây dựng pipeline chất lọc tri thức đa phương thức cho bài toán dự đoán ECR video ngắn, kết hợp hard label, soft ECR, clip ECR, hidden alignment, attention transfer và ranking distillation.
- **Thiết kế Student triển khai được:** Xây dựng Student dựa trên temporal Transformer nhẹ, source-specific text embedding và fusion MLP, chỉ dùng các đầu vào rẻ hơn tại thời điểm suy luận.
- **Bổ sung phân tích giới hạn thông tin:** Thực nghiệm upper-bound compressed Student đạt Final Score **0.6947**, gần Teacher **0.7038**, chỉ ra rằng khoảng cách còn lại chủ yếu đến từ thiếu hụt thông tin đầu vào.
- **Kết quả thực nghiệm nhất quán:** Cấu hình tốt nhất SnapUGC-LightKD Edge Ensemble đạt PLCC **0.6372**, SRCC **0.6302** và Final Score **0.6330**, cải thiện **+0.0737** so với baseline Student mở rộng trên cùng split kiểm định. Mốc **0.6027** được dùng như cấu hình diagnostic v35, không phải kết quả tốt nhất cuối cùng.

Chương 2

Các công trình nghiên cứu liên quan

Chương này đặt đề tài vào bối cảnh nghiên cứu rộng hơn trước khi đi vào các nền tảng kỹ thuật ở Chương 3. Theo cách tổ chức của các báo cáo mẫu, phần công trình liên quan được trình bày như một khảo sát có chọn lọc: mỗi nhóm công trình được mô tả theo mục tiêu, cách tiếp cận chính, hạn chế còn tồn tại và liên hệ trực tiếp đến SnapUGC-LightKD. Các chi tiết kiến trúc của những mô hình chỉ được dùng như bộ sinh đặc trưng của Teacher sẽ không được triển khai sâu ở đây; chúng được xem như các công trình tham chiếu hoặc nguồn artifact cho quá trình chất lọc.

2.1 Dự đoán tương tác và chất lượng video UGC ngắn

2.1.1 Từ đánh giá chất lượng video đến dự đoán tương tác

Đánh giá chất lượng video truyền thống thường tập trung vào chất lượng cảm nhận thị giác, chẳng hạn độ mờ, nhiễu nén, biến dạng màu sắc hoặc hiện tượng giật hình. Các bài toán này hữu ích trong truyền phát

video và tối ưu codec, nhưng chưa phản ánh đầy đủ hành vi của người xem trên nền tảng video ngắn. Một video có chất lượng kỹ thuật cao vẫn có thể bị bỏ qua nếu nội dung không hấp dẫn; ngược lại, một video có độ phân giải thấp vẫn có thể giữ chân người xem nếu có chuyển động bất ngờ, âm thanh cuốn hút hoặc chủ đề gây tò mò.

Sự phát triển của nội dung do người dùng tạo ra (User-Generated Content – UGC) làm thay đổi mục tiêu đánh giá. Thay vì chỉ dự đoán Mean Opinion Score, các nghiên cứu gần đây quan tâm nhiều hơn đến engagement, retention và khả năng duy trì chú ý. SnapUGC [1] là một bộ dữ liệu tiêu biểu trong hướng này khi sử dụng ECR làm thước đo phản ánh hành vi tiếp tục xem của người dùng. So với nhãn chất lượng cảm nhận, ECR gần hơn với nhu cầu của hệ thống đề xuất nội dung vì nó đánh giá khả năng video giữ người xem theo tiến trình thời gian.

2.1.2 Đặc thù của chỉ số ECR

ECR khác với lượt xem hoặc lượt thích ở chỗ nó nhấn mạnh quá trình duy trì tương tác theo thời gian. Việc dự đoán ECR khó hơn phân loại nhị phân vì nhãn chịu ảnh hưởng đồng thời của nội dung, ngữ cảnh nền tảng, hành vi người dùng và nhiều thống kê. Do đó, các phương pháp mạnh thường cần mô hình hóa nhiều nguồn tín hiệu: hình ảnh tĩnh, chuyển động, âm thanh, văn bản metadata, caption và chất lượng hiển thị.

Trong phạm vi luận văn, ECR được xử lý như một bài toán hồi quy trong khoảng $[0, 1]$. Điều này dẫn đến hai yêu cầu quan trọng. Thứ nhất, mô hình cần dự đoán giá trị liên tục ổn định chứ không chỉ phân loại video tốt/xấu. Thứ hai, thứ hạng tương đối giữa các video cũng quan trọng vì hệ thống đề xuất thường quan tâm video nào nên được ưu tiên hơn. Các yêu cầu này là lý do luận văn kết hợp loss hồi quy với các tín hiệu ranking từ Teacher.

2.1.3 Các hệ thống Teacher đa phương thức

Các hệ thống mạnh cho video UGC thường tích hợp nhiều backbone. Với SnapUGC, Teacher tham chiếu kết hợp đặc trưng thị giác, méo ảnh, hành động, caption, âm thanh và metadata văn bản. Điểm mạnh của hướng này là khả năng bao quát nhiều nguyên nhân làm người xem tiếp tục xem video. Điểm yếu là chi phí suy luận cao vì một số nhánh như backbone hành động, mô hình caption video-text hoặc text encoder lớn không phù hợp để chạy trực tiếp trên thiết bị biên.

Khoảng trống nghiên cứu xuất hiện ở đây: làm thế nào để giữ lại tri thức của Teacher đa phương thức nhưng chuyển sang một Student nhẹ hơn, không cần chạy toàn bộ feature stack ở thời điểm suy luận? Đây chính là động lực của SnapUGC-LightKD. Luận văn không cố mô tả lại chi tiết mọi backbone của Teacher, mà tập trung vào giao diện tri thức mà Teacher cung cấp cho Student: điểm ECR mềm, ECR theo clip, hidden state, attention và một số đặc trưng đặc quyền.

2.2 Học biểu diễn đa phương thức trong video

2.2.1 Các hướng fusion đa phương thức

Một câu hỏi trung tâm của học đa phương thức là hợp nhất các modality ở giai đoạn nào. Fusion sớm nổi đặc trưng ngay từ đầu, fusion muộn dự đoán riêng từng modality rồi kết hợp điểm, còn các kiến trúc attention cho phép một modality truy vấn modality khác. Các hướng như Gated Multimodal Unit [6] cho thấy việc học trọng số đóng góp theo modality có thể giúp mô hình xử lý nhiều hoặc thiếu thông tin giữa các nguồn.

Trong Teacher lớn, cross-attention và các nhánh fusion phức tạp phù hợp vì mô hình có đủ dung lượng và nhiều nguồn đặc trưng. Trong Student nhẹ, luận văn ưu tiên fusion đơn giản hơn: chiếu đặc trưng video, mã hóa

các embedding văn bản theo nguồn, sau đó hợp nhất bằng attention pooling và MLP. Thiết kế này chấp nhận giảm một phần độ biểu diễn để đổi lấy khả năng triển khai.

2.2.2 Vai trò của văn bản metadata

Tiêu đề và mô tả video là tín hiệu đặc biệt. Chúng có thể cung cấp chủ đề mà khung hình chưa biểu đạt rõ, nhưng cũng có thể gây nhiễu do clickbait. Nhân âm thanh dạng text, title và description vì vậy không nên bị đối xử như ba token đồng nhất. Điều này dẫn đến thiết kế source-specific text embedding trong SnapUGC-LightKD, được trình bày chi tiết ở Chương 4.

Các mô hình như CLIP [7] và mPLUG-2 [8] cho thấy lợi ích của việc học biểu diễn chung giữa thị giác và ngôn ngữ. Tuy nhiên, trong luận văn này các mô hình đó chủ yếu đóng vai trò nguồn tham chiếu hoặc bộ sinh đặc trưng; phần nền tảng chỉ giữ lại các khái niệm cần thiết cho việc hiểu giao diện artifact và quyết định thiết kế Student.

2.2.3 Hạn chế của đặc trưng thủ công

Các đặc trưng thủ công như độ mờ, độ sáng, độ nhiễu hoặc sai khác khung hình có ưu điểm rẻ và dễ tính. Tuy nhiên, chúng thường có hai hạn chế. Một là chúng chỉ mô tả tín hiệu cấp thấp, khó nắm bắt ngữ nghĩa. Hai là khi đưa vào mạng nhỏ, đặc trưng thô có thể làm tăng chiều đầu vào mà không tăng thông tin hữu ích tương ứng. Kết quả thực nghiệm ở Chương 5 cho thấy hiện tượng này rõ ràng: bổ sung đặc trưng OpenCV hoặc raw audio logits không cải thiện Student deployable.

2.3 Chất lọc tri thức cho mô hình đa phương thức

2.3.1 Từ KD đầu ra đến KD biểu diễn

KD cổ điển tập trung vào đầu ra của Teacher [2]. Với bài toán hồi quy ECR, response-based KD tương ứng với việc khớp điểm ECR của Teacher. Tuy nhiên, Teacher đa phương thức chứa nhiều tri thức hơn điểm cuối. Hidden state, attention map và thứ hạng tương đối giữa mẫu đều là nguồn giám sát có giá trị. Các khảo sát về KD [9], [10] cũng cho thấy xu hướng hiện đại không chỉ nén logits mà còn chuyển giao biểu diễn và quan hệ giữa mẫu.

Feature-based KD như FitNets [3] chuyển giao biểu diễn trung gian. Attention Transfer [4] chuyển giao vị trí mà Teacher tập trung. Relational KD [5] chuyển giao cấu trúc quan hệ giữa mẫu. Trong SnapUGC-LightKD, các nhóm tri thức này được kết hợp để Student học cả giá trị, biểu diễn và cấu trúc thứ hạng.

2.3.2 Chất lọc trong bài toán hồi quy và xếp hạng

Nhiều bài toán chất lượng video không chỉ cần sai số hồi quy thấp mà còn cần tương quan thứ hạng cao. Nếu hai video có ECR rất gần nhau, việc dự đoán sai một lượng nhỏ có thể ít nghiêm trọng; nhưng nếu mô hình đảo thứ hạng giữa video rất hấp dẫn và video kém hấp dẫn, hệ thống gợi ý sẽ bị ảnh hưởng lớn. Các hướng như RankDVQA-mini [11] cho thấy KD có thể được khai thác để cải thiện đánh giá chất lượng video trong bối cảnh mô hình nhẹ. Luận văn kế thừa trực giác này bằng cách dùng cả thứ hạng theo nhãn thật và thứ hạng theo Teacher để tăng độ ổn định.

2.4 LUPI và học từ thông tin đặc quyền

LUPI [12] cung cấp khung lý thuyết cho tình huống có thông tin phụ trong huấn luyện nhưng không có ở suy luận. Trong học đa phương thức, tình huống này rất phổ biến: dữ liệu huấn luyện có thể có ảnh chiều sâu, caption, annotation hoặc đặc trưng từ mô hình lớn, trong khi hệ thống triển khai chỉ có RGB hoặc đặc trưng rẻ hơn. Cross Modal Distillation [13] cho thấy Student có thể học từ modality đặc quyền bằng cách tái tạo hoặc bắt chước biểu diễn của Teacher.

Trong SnapUGC-LightKD, ResNet3D action feature và mPLUG-2 caption feature là thông tin đặc quyền. Chúng không được dùng làm đầu vào suy luận của Student, nhưng xuất hiện trong loss hallucination. Đây là điểm khác biệt giữa việc chỉ nén mô hình và việc học có thông tin đặc quyền: Student không chỉ học đầu ra, mà học cấu trúc ngữ nghĩa ẩn mà Teacher suy luận được từ các modality đắt tiền.

2.5 Kết luận khảo sát và định vị SnapUGC-LightKD

Từ các nhóm công trình trên, có thể rút ra ba khoảng trống chính. Thứ nhất, các Teacher đa phương thức cho ECR mạnh nhưng nặng, khó triển khai. Thứ hai, các Student nhẹ nếu chỉ học nhãn cứng dễ bị giới hạn bởi nhiều nhãn và thiếu thông tin đầu vào. Thứ ba, việc bổ sung đặc trưng thô không bảo đảm cải thiện nếu đặc trưng đó không mang thông tin ngữ nghĩa đủ cao.

SnapUGC-LightKD được định vị ở giao điểm của ba hướng: dự đoán ECR video UGC, chất lọc tri thức đa tầng và học với thông tin đặc quyền. Phương pháp không cố gắng chạy Teacher nhỏ hơn một cách trực tiếp; thay vào đó, nó huấn luyện Student triển khai được bằng nhiều tín hiệu Teacher, rồi giữ lại một luồng suy luận gọn nhẹ. Trên cơ sở khảo sát này, Chương 3

chỉ trình bày những nền tảng kỹ thuật thật sự cần để hiểu phương pháp, trước khi Chương 4 mô tả chi tiết thiết kế SnapUGC-LightKD.

Chương 3

Các công trình nền tảng

Sau khi Chương 2 đã đặt đề tài vào bối cảnh các công trình liên quan, chương này chỉ trình bày các nền tảng kỹ thuật trực tiếp cần cho SnapUGC-LightKD. Trọng tâm của chương là cơ chế Transformer dùng trong Student, giao diện đặc trưng/artifact mà Teacher cung cấp, và các nguyên lý chất lọc tri thức được dùng trong hệ loss. Những backbone của Teacher chỉ được chạy để sinh artifact hoặc làm nguồn tham chiếu sẽ được nhắc kèm trích dẫn thay vì phân tích chi tiết kiến trúc.

3.1 Kiến trúc Transformer và Cơ chế Tự chú ý

Transformer là một trong những kiến trúc trung tâm của học sâu hiện đại. Trong ngữ cảnh của luận văn này, Transformer đóng vai trò kép. Thứ nhất, nhiều mô hình nền tảng như Vision Transformer, CLIP text encoder hay các khối hợp nhất của Teacher đều kế thừa trực tiếp cơ chế tự chú ý. Thứ hai, Student của SnapUGC-LightKD sử dụng một temporal Transformer nhẹ để mô hình hóa chuỗi đặc trưng clip theo thời gian. Vì vậy, việc trình bày tường minh Self-Attention và Multi-Head Attention là điều kiện cần để hiểu các quyết định thiết kế ở những chương sau.

3.1.1 Động lực ra đời

Các mô hình tuần tự truyền thống như RNN, LSTM hay GRU xử lý chuỗi theo thứ tự thời gian. Với chuỗi đầu vào gồm T phần tử, trạng thái ẩn tại thời điểm t thường phụ thuộc đệ quy vào trạng thái trước đó:

$$h_t = f_\theta(x_t, h_{t-1}), \quad t = 1, 2, \dots, T. \quad (3.1)$$

Cách mô hình hóa này phù hợp với chuỗi ngắn, nhưng tạo ra hai hạn chế lớn. Một là quá trình huấn luyện khó song song hóa vì phải tính tuần tự từ h_1 đến h_T . Hai là tín hiệu gradient khi lan truyền ngược qua nhiều bước thời gian dễ suy giảm hoặc bùng nổ, khiến mô hình gặp khó khăn khi học phụ thuộc dài hạn.

Các cơ chế attention ban đầu như Bahdanau Attention [14] và Luong Attention [15] đã cho thấy mô hình không nhất thiết phải nén toàn bộ chuỗi nguồn vào một vector trạng thái duy nhất. Thay vào đó, mô hình có thể học trọng số chú ý $\alpha_{t,s}$ để chọn các vị trí quan trọng của chuỗi nguồn khi sinh đầu ra. Tuy nhiên, các cơ chế này vẫn thường được đặt trong khung encoder-decoder dựa trên RNN, do đó chưa giải quyết triệt để vấn đề tuần tự hóa.

Transformer của Vaswani và cộng sự [16] loại bỏ hoàn toàn hồi quy, thay thế bằng Self-Attention. Ý tưởng cốt lõi là mọi token trong chuỗi có thể quan sát trực tiếp mọi token khác thông qua phép nhân ma trận. Với video ngắn, điều này tương ứng với việc một clip ở đầu video có thể tương tác trực tiếp với một clip ở cuối video, giúp mô hình học các quan hệ ngữ nghĩa và chuyển động dài hạn mà không cần truyền trạng thái qua từng bước.

3.1.2 Biểu diễn token và positional encoding

Self-Attention bản thân không chứa giả định về thứ tự. Nếu hoán vị các token đầu vào và hoán vị tương ứng các hàng của ma trận, kết quả

attention cũng bị hoán vị theo. Do đó, Transformer cần bổ sung thông tin vị trí vào biểu diễn đầu vào. Với chuỗi token $X \in \mathbb{R}^{T \times d_{model}}$, biểu diễn đưa vào tầng Transformer thường có dạng:

$$Z^{(0)} = X + P, \quad (3.2)$$

trong đó $P \in \mathbb{R}^{T \times d_{model}}$ là ma trận positional embedding. Trong các mô hình hiện đại, P có thể được học trực tiếp hoặc được định nghĩa bằng các hàm sin-cos cố định:

$$P_{t,2i} = \sin\left(\frac{t}{10000^{2i/d_{model}}}\right), \quad P_{t,2i+1} = \cos\left(\frac{t}{10000^{2i/d_{model}}}\right). \quad (3.3)$$

Trong bài toán video, t có thể được hiểu là chỉ số clip hoặc chỉ số khung hình sau khi đã trích xuất đặc trưng. Việc cộng positional embedding giúp mô hình phân biệt giữa các hiện tượng xuất hiện ở đầu, giữa hoặc cuối video, vốn có ý nghĩa lớn đối với chỉ số giữ chân người xem ECR.

3.1.3 Scaled Dot-Product Attention

Giả sử đầu vào của một tầng attention là $Z \in \mathbb{R}^{T \times d_{model}}$. Transformer tạo ra ba ma trận Query, Key và Value bằng các phép chiếu tuyến tính:

$$Q = ZW^Q, \quad K = ZW^K, \quad V = ZW^V, \quad (3.4)$$

trong đó:

$$W^Q \in \mathbb{R}^{d_{model} \times d_k}, \quad W^K \in \mathbb{R}^{d_{model} \times d_k}, \quad W^V \in \mathbb{R}^{d_{model} \times d_v}. \quad (3.5)$$

Trực giác của ba ma trận này như sau. Query biểu diễn nhu cầu truy vấn thông tin của một token; Key biểu diễn dấu hiệu để token khác được truy vấn; Value chứa nội dung thực sự được tổng hợp. Độ tương thích giữa

token i và token j được tính bằng tích vô hướng:

$$s_{ij} = q_i^\top k_j. \quad (3.6)$$

Các điểm tương thích được chuẩn hóa bằng softmax để tạo trọng số chú ý:

$$a_{ij} = \frac{\exp(s_{ij}/\sqrt{d_k})}{\sum_{m=1}^T \exp(s_{im}/\sqrt{d_k})}. \quad (3.7)$$

Khi viết dưới dạng ma trận, Scaled Dot-Product Attention được định nghĩa là:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V. \quad (3.8)$$

Hệ số $\sqrt{d_k}$ trong Công thức (3.8) có vai trò ổn định phân phối điểm attention. Giả sử các thành phần của q_i và k_j độc lập, có kỳ vọng 0 và phương sai 1. Khi đó tích vô hướng có phương sai xấp xỉ:

$$\text{Var}(q_i^\top k_j) = \text{Var}\left(\sum_{r=1}^{d_k} q_{i,r} k_{j,r}\right) \approx d_k. \quad (3.9)$$

Nếu d_k lớn, các giá trị s_{ij} có độ lớn cao, làm softmax rơi vào vùng bão hòa: một vài trọng số gần 1, phần còn lại gần 0. Khi softmax bão hòa, đạo hàm của nó trở nên rất nhỏ, khiến gradient truyền ngược qua attention bị triệt tiêu. Việc chia cho $\sqrt{d_k}$ đưa phương sai của điểm chú ý về xấp xỉ 1:

$$\text{Var}\left(\frac{q_i^\top k_j}{\sqrt{d_k}}\right) \approx 1, \quad (3.10)$$

nhờ đó phân phối softmax ít cực đoan hơn, gradient ổn định hơn và quá trình huấn luyện hội tụ tốt hơn.

3.1.4 Multi-Head Attention

Một đầu attention duy nhất chỉ học một kiểu quan hệ giữa các token. Trong video, các quan hệ có thể rất đa dạng: tương đồng ngữ nghĩa giữa hai khung hình, biến đổi chuyển động nhanh, sự xuất hiện của nhân vật, hoặc mối quan hệ giữa phần mở đầu và cao trào. Multi-Head Attention giải quyết vấn đề này bằng cách chiếu đầu vào sang nhiều không gian con, sau đó tính attention độc lập trong từng không gian.

Với số đầu là h , đầu thứ r được định nghĩa bởi các ma trận chiều riêng:

$$Q_r = ZW_r^Q, \quad K_r = ZW_r^K, \quad V_r = ZW_r^V, \quad r = 1, 2, \dots, h. \quad (3.11)$$

Các ma trận trọng số của từng đầu có kích thước:

$$W_r^Q \in \mathbb{R}^{d_{model} \times d_k}, \quad W_r^K \in \mathbb{R}^{d_{model} \times d_k}, \quad W_r^V \in \mathbb{R}^{d_{model} \times d_v}. \quad (3.12)$$

Đầu attention thứ r được tính như sau:

$$\text{head}_r = \text{Attention}(Q_r, K_r, V_r) = \text{softmax} \left(\frac{Q_r K_r^\top}{\sqrt{d_k}} \right) V_r. \quad (3.13)$$

Sau khi tính tất cả các đầu, Transformer nối các biểu diễn theo chiều đặc trưng và chiếu về lại không gian d_{model} :

$$\text{MultiHead}(Z) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h) W^O, \quad (3.14)$$

trong đó:

$$W^O \in \mathbb{R}^{hd_v \times d_{model}}. \quad (3.15)$$

Ma trận W^O không chỉ giảm chiều sau phép nối, mà còn học cách trộn thông tin từ các đầu attention khác nhau. Nếu mỗi đầu được xem như một chuyên gia học một loại quan hệ, W^O đóng vai trò bộ hợp nhất để tạo biểu diễn chung.

Trong triển khai Student của luận văn, hidden dimension nhỏ $d_{model} =$

96 và số đầu $h = 4$. Khi đó mỗi đầu attention chỉ xử lý một không gian con tương đối nhỏ, giúp giảm chi phí tính toán nhưng vẫn giữ được khả năng học nhiều kiểu phụ thuộc thời gian khác nhau.

3.1.5 Khối Transformer encoder

Một tầng Transformer encoder hoàn chỉnh gồm Multi-Head Attention, residual connection, layer normalization và mạng truyền thẳng theo vị trí. Với đầu vào $Z^{(\ell)}$, tầng thứ ℓ có thể được viết như sau:

$$\tilde{Z}^{(\ell)} = \text{LayerNorm} \left(Z^{(\ell)} + \text{MultiHead}(Z^{(\ell)}) \right), \quad (3.16)$$

$$Z^{(\ell+1)} = \text{LayerNorm} \left(\tilde{Z}^{(\ell)} + \text{FFN}(\tilde{Z}^{(\ell)}) \right). \quad (3.17)$$


Mạng truyền thẳng theo vị trí thường là một MLP hai lớp áp dụng độc lập cho từng token:

$$\text{FFN}(z) = W_2 \phi(W_1 z + b_1) + b_2, \quad (3.18)$$

trong đó $\phi(\cdot)$ thường là ReLU hoặc GELU. Residual connection giúp gradient có đường truyền ngắn qua nhiều tầng, còn layer normalization làm ổn định thang đo của activation.

3.1.6 Vai trò trong SnapUGC-LightKD

Trong SnapUGC-LightKD, Transformer không được dùng như một backbone khổng lồ, mà như một khối mô hình hóa thời gian gọn nhẹ. Chuỗi `frame_fusion_feature` của video được xem như một chuỗi token theo clip. Sau khi chiếu về $d_{model} = 96$, chuỗi này đi qua một tầng Transformer encoder để học quan hệ giữa các đoạn video. Attention pooling sau đó tổng hợp chuỗi thành vector video cấp toàn cục. Cách thiết kế này phản ánh một thỏa hiệp quan trọng: giữ lại năng lực học phụ thuộc dài



Hình 3.1: Khối Transformer encoder dùng để mô hình hóa quan hệ giữa các token hoặc clip.

hạn của Transformer nhưng giới hạn số tầng và số chiều để phù hợp với mục tiêu triển khai nhẹ.

Từ nền tảng Transformer, phần tiếp theo chuyển sang các backbone đa phương thức. Các backbone này là nguồn tạo ra đặc trưng giàu thông tin cho Teacher và cũng là nguồn tri thức mà Student cần học thông qua chất lọc.

3.2 Giao diện đặc trưng đa phương thức và artifact Teacher

Dự đoán ECR của video ngắn là một bài toán đa phương thức tự nhiên. Người xem không chỉ phản ứng với hình ảnh tĩnh, mà còn với chuyển động, âm thanh, tiêu đề, mô tả, caption và chất lượng cảm nhận. Tuy nhiên, luận văn không huấn luyện lại hoặc thay đổi chi tiết các backbone lớn của Teacher. Các mô hình này chủ yếu được dùng để tạo artifact offline; Student học từ giao diện artifact đó thông qua KD. Vì vậy, phần này tập trung vào vai trò của từng nhóm đặc trưng thay vì triển khai lại công thức nội bộ của từng backbone.

3.2.1 Tổng quan giao diện Teacher–Student

Teacher tham chiếu sử dụng một feature stack nhiều nhánh. Mỗi nhánh quan sát một khía cạnh khác nhau của video, sau đó các biểu diễn được hợp nhất để dự đoán ECR. Đối với SnapUGC-LightKD, điều quan trọng không phải là tái hiện toàn bộ Teacher, mà là phân loại artifact nào được dùng khi suy luận và artifact nào chỉ dùng trong huấn luyện. Bảng 3.1 tóm tắt giao diện này.

Điểm quan trọng là không phải tất cả artifact đều rẻ để có ở thời điểm suy luận. Các nhánh như action/caption mang nhiều thông tin nhưng chi phí cao. Vì vậy, chúng được chuyển thành mục tiêu huấn luyện thay vì đầu vào bắt buộc khi triển khai.

Bảng 3.1: Các nhóm artifact đa phương thức trong SnapUGC-LightKD

Nhóm artifact	Nguồn/kiểu tín hiệu	Cách dùng trong luận văn
frame_fusion feature	Đặc trưng video đã hợp nhất từ Teacher	Đầu vào video chính của Student deployable
text_pooled	Embedding văn bản theo nguồn	Đầu vào văn bản của Student, có source-specific embedding
teacher_ecr, clip_ecr	Dự đoán mềm cấp video và clip	Mục tiêu KD ở đầu ra và theo thời gian
temporal hidden, fusion hidden	Biểu diễn ẩn của Teacher	Căn chỉnh biểu diễn bằng loss hidden/cosine
attention importance	Phân bố chú ý theo clip	Căn chỉnh attention để học clip quan trọng
action feature, caption feature	Đặc trưng đặc quyền từ nhánh hành động/caption	Chỉ dùng trong huấn luyện qua hallucination, không dùng ở suy luận

3.2.2 Các backbone Teacher được xem như nguồn artifact

Teacher không học mọi thành phần từ đầu trên tập SnapUGC. Thay vào đó, hệ thống tận dụng nhiều mô hình tiền huấn luyện để tạo biểu diễn ổn định. Vì luận văn không can thiệp vào chi tiết các mô hình này, chúng chỉ được nhắc ở mức vai trò:

- **EfficientNetV2** [17]: cung cấp đặc trưng ngữ nghĩa khung hình và bối cảnh thị giác.
- **Distortion backbone**: cung cấp tín hiệu chất lượng cảm nhận như méo ảnh, nén và nhiễu.
- **ResNet3D/R(2+1)D** [18]: cung cấp đặc trưng hành động/chuyển động theo clip, dùng như thông tin đặc quyền.
- **mPLUG-2** [8]: sinh caption và đặc trưng video-text cấp cao, dùng như thông tin đặc quyền.
- **YAMNet và text encoder**: chuyển tín hiệu âm thanh, title và description thành embedding văn bản cho Student.
- **CLIP/ViT** [7], [19]: cung cấp trực giác về biểu diễn ảnh-văn bản và được dùng ở một số cấu hình mở rộng của Student.

Việc sử dụng mô hình tiền huấn luyện giúp Teacher có năng lực biểu diễn mạnh dù tập con huấn luyện trong luận văn chỉ gồm 5.000 video. Tuy nhiên, chính điều này cũng tạo ra khoảng cách triển khai: Student nhẹ không thể chạy toàn bộ các mô hình lớn đó. Khoảng cách này là lý do tồn tại của Knowledge Distillation và LUPI, được trình bày trong mục tiếp theo.

3.2.3 Nguyên tắc chọn nội dung nền tảng

Từ góc nhìn viết luận văn, những mô hình Teacher chỉ được gọi để suy luận offline không cần được triển khai công thức chi tiết. Nội dung cần giữ lại là: chúng tạo loại artifact nào, artifact đó có xuất hiện khi Student suy luận hay không, và artifact đó đi vào loss nào. Ngược lại, các thành phần trực tiếp nằm trong Student hoặc hệ loss như temporal Transformer, attention pooling, hidden alignment, ranking loss và hallucination cần được trình bày kỹ hơn vì chúng là phần luận văn thật sự thiết kế và đánh giá.

3.3 Lý thuyết Chắt lọc Tri thức

Knowledge Distillation (KD) là cơ chế chuyển giao tri thức từ mô hình lớn sang mô hình nhỏ. Trong luận văn, KD không chỉ là một kỹ thuật nén mô hình, mà là cơ chế trung tâm để Student học từ các tín hiệu mà nó không thể quan sát trực tiếp khi suy luận. Mục này trình bày KD gốc của Hinton, sau đó mở rộng sang các dạng chắt lọc đặc trưng, chú ý, quan hệ và thông tin đặc quyền.

3.3.1 Hinton KD và softmax với nhiệt độ

Trong bài toán phân loại với C lớp, mô hình Teacher sinh vector logit:

$$z^T = [z_1^T, z_2^T, \dots, z_C^T] \in \mathbb{R}^C. \quad (3.19)$$

Softmax thông thường biến logit thành phân phối xác suất:

$$p_i = \frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)}. \quad (3.20)$$

Hinton KD [2] đưa vào tham số nhiệt độ $T > 0$ để làm mềm phân phối:

$$p_i^T(T) = \frac{\exp(z_i^T/T)}{\sum_{j=1}^C \exp(z_j^T/T)}. \quad (3.21)$$

Tương tự, phân phối mềm của Student là:

$$p_i^S(T) = \frac{\exp(z_i^S/T)}{\sum_{j=1}^C \exp(z_j^S/T)}. \quad (3.22)$$

Khi $T = 1$, ta thu được softmax thông thường. Khi T tăng, xác suất của các lớp không tối ưu cũng tăng lên, để lộ thông tin về tương quan giữa các lớp. Ví dụ, nếu Teacher cho rằng một ảnh chó có xác suất nhỏ nhưng đáng kể thuộc lớp sói, phân phối mềm này chứa tri thức ngữ nghĩa mà nhãn cứng không thể hiện.

3.3.2 KL-Divergence trong chất lọc

Để ép Student mô phỏng phân phối mềm của Teacher, KD sử dụng Kullback–Leibler Divergence:

$$\text{KL}(p^T(T) \parallel p^S(T)) = \sum_{i=1}^C p_i^T(T) \log \frac{p_i^T(T)}{p_i^S(T)}. \quad (3.23)$$

Loss KD thường được nhân với T^2 để bù lại ảnh hưởng của nhiệt độ lên độ lớn gradient:

$$\mathcal{L}_{KD} = T^2 \text{KL}(p^T(T) \parallel p^S(T)). \quad (3.24)$$

Tổng loss trong KD phân loại kết hợp giữa nhãn cứng và phân phối mềm:

$$\mathcal{L} = \alpha \mathcal{L}_{CE}(y, p^S) + (1 - \alpha) \mathcal{L}_{KD}, \quad (3.25)$$

trong đó α điều khiển mức độ tin vào nhãn thật so với Teacher.

3.3.3 Chất lọc cho bài toán hồi quy ECR

Bài toán ECR trong luận văn là hồi quy chứ không phải phân loại. Teacher không sinh phân phối lớp mà sinh điểm ECR liên tục $\hat{y}_T \in [0, 1]$. Vì vậy, logit KD được chuyển thành matching đầu ra bằng sai số bình phương:

$$\mathcal{L}_{soft_ECR} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_{S,i} - \hat{y}_{T,i})^2. \quad (3.26)$$

Nhân thật vẫn được dùng thông qua loss hồi quy cứng:

$$\mathcal{L}_{hard} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_{S,i} - y_i)^2. \quad (3.27)$$

Trong ngữ cảnh ECR, điểm Teacher được xem như nhãn mềm vì nó tổng hợp tri thức từ nhiều modality và ít nhiều hơn nhãn quan sát trực tiếp. Nhân thật y_i có thể bị ảnh hưởng bởi thuật toán phân phối nền tảng, thời điểm đăng hoặc độ nổi tiếng tài khoản; Teacher giúp làm mượt một phần các nhiễu này.

3.3.4 FitNets và chất lọc đặc trưng ẩn

KD ở đầu ra không đủ để truyền toàn bộ tri thức. FitNets [3] đề xuất căn chỉnh biểu diễn trung gian của Student và Teacher. Giả sử Teacher có đặc trưng ẩn $F_T \in \mathbb{R}^{d_T}$ và Student có đặc trưng $F_S \in \mathbb{R}^{d_S}$ với $d_S < d_T$. Một hàm chiếu r_ϕ đưa Student sang không gian Teacher:

$$\tilde{F}_S = r_\phi(F_S). \quad (3.28)$$

Loss căn chỉnh có thể dùng MSE hoặc cosine distance:

$$\mathcal{L}_{FitNet} = \left\| \tilde{F}_S - F_T \right\|_2^2, \quad (3.29)$$

hoặc:

$$\mathcal{L}_{cos} = 1 - \frac{\tilde{F}_S^\top F_T}{\|\tilde{F}_S\|_2 \|F_T\|_2}. \quad (3.30)$$

Trong SnapUGC-LightKD, cosine alignment phù hợp vì hướng biểu diễn ngữ nghĩa quan trọng hơn độ lớn tuyệt đối của activation.

3.3.5 Attention Transfer

Attention Transfer [4] buộc Student học cách phân bổ chú ý tương tự Teacher. Với video, attention không chỉ là bản đồ không gian mà còn là phân phối theo thời gian. Giả sử Teacher sinh phân phối attention theo clip $A_T \in \Delta^{T-1}$ và Student sinh $A_S \in \Delta^{T-1}$, loss attention có thể viết:

$$\mathcal{L}_{attn} = \text{KL}(A_T \| A_S) = \sum_{t=1}^T A_{T,t} \log \frac{A_{T,t} + \epsilon}{A_{S,t} + \epsilon}. \quad (3.31)$$

Hệ số ϵ tránh logarit của 0. Thành phần này giúp Student học clip nào có ảnh hưởng lớn đến ECR, ví dụ đoạn mở đầu gây chú ý hoặc đoạn cao trào khiến người xem tiếp tục xem.

3.3.6 Relational KD và cấu trúc thứ hạng

Relational KD [5] không chỉ so khớp từng mẫu riêng lẻ, mà bảo toàn quan hệ giữa các mẫu trong batch. Với hai mẫu i và j , quan hệ thứ hạng theo Teacher có thể được xác định bởi dấu của hiệu điểm:

$$r_{ij}^T = \text{sign}(\hat{y}_{T,i} - \hat{y}_{T,j}). \quad (3.32)$$

Student được khuyến khích tạo hiệu điểm cùng dấu:

$$\mathcal{L}_{rank} = \sum_{i < j} \max(0, m - r_{ij}^T(\hat{y}_{S,i} - \hat{y}_{S,j})), \quad (3.33)$$

trong đó m là margin. Thành phần này đặc biệt phù hợp với ECR vì trong nhiều ứng dụng, việc xếp hạng video hấp dẫn hơn quan trọng không kém việc dự đoán chính xác giá trị tuyệt đối.

3.3.7 LUPI và mạng ảo ảnh

Learning using Privileged Information (LUPI) [12] giả định trong huấn luyện có tồn tại thông tin X^* chỉ khả dụng ở pha huấn luyện nhưng không có lúc suy luận. Trong luận văn, đặc trưng hành động ResNet3D và đặc trưng caption mPLUG-2 đóng vai trò X^* . Student không nhận các đặc trưng này khi triển khai, nhưng được học tái tạo chúng trong huấn luyện:

$$\hat{X}_S^* = g_\psi(F_S), \quad (3.34)$$

$$\mathcal{L}_{LUPI} = d\left(\hat{X}_S^*, X_T^*\right), \quad (3.35)$$

trong đó g_ψ là mạng ảo ảnh và $d(\cdot, \cdot)$ là hàm khoảng cách biểu diễn. Cơ chế này giúp Student học các hướng biến thiên ngữ nghĩa liên quan đến hành động/caption, dù không trực tiếp quan sát chúng khi suy luận.

3.4 Phân tích độ phức tạp và ý nghĩa thiết kế đối với mô hình nhẹ

Các mô hình nền tảng và backbone Teacher có năng lực biểu diễn mạnh, nhưng chi phí tính toán của chúng tăng nhanh theo số token, số khung hình và số modality. Vì luận văn không đi sâu vào nội bộ từng Teacher backbone, phần này chỉ phân tích chi phí ở mức khái quát để giải thích vì sao Student cần nhẹ và vì sao một số artifact chỉ nên dùng trong huấn luyện.

3.4.1 Độ phức tạp của Self-Attention

Với chuỗi T token và hidden dimension d , phép tính attention cần tạo ma trận tương đồng $QK^\top \in \mathbb{R}^{T \times T}$. Độ phức tạp chính là:

$$\mathcal{O}_{attn} = \mathcal{O}(T^2 d). \quad (3.36)$$

Bộ nhớ để lưu attention map cũng tăng theo:

$$\mathcal{M}_{attn} = \mathcal{O}(hT^2), \quad (3.37)$$

trong đó h là số attention heads. Với ảnh hoặc video, T có thể rất lớn nếu mỗi patch hoặc mỗi frame được xem như một token. Vì vậy, Student của luận văn không dùng token ảnh thô mà dùng chuỗi đặc trưng clip đã rút gọn. Cách làm này giảm T và giảm d , qua đó giảm chi phí theo cả hai chiều.

3.4.2 Độ phức tạp của backbone video

Backbone hành động như ResNet3D có chi phí cao vì tích chập mở rộng trên cả ba chiều thời gian–không gian. Nếu feature map có kích thước $T \times H \times W$ và kernel có kích thước $k_t \times k_h \times k_w$, chi phí tích chập 3D xấp xỉ:

$$\mathcal{O}_{3D} = \mathcal{O}(THWk_tk_hk_wC_{in}C_{out}). \quad (3.38)$$

Trong môi trường suy luận di động, chi phí này không chỉ ảnh hưởng thời gian phản hồi mà còn ảnh hưởng bộ nhớ, nhiệt độ thiết bị và pin. Do đó, ResNet3D phù hợp để sinh tri thức đặc quyền trong huấn luyện, nhưng không phù hợp làm nhánh suy luận mặc định của Student.

3.4.3 Độ phức tạp của mô hình caption và text encoder lớn

Các mô hình video–language như mPLUG-2 có nhiều tầng Transformer và thường xử lý cả token ảnh/video lẫn token văn bản. Nếu số token video là T_v và số token văn bản là T_t , cross-attention có độ phức tạp:

$$\mathcal{O}_{cross} = \mathcal{O}(T_v T_t d). \quad (3.39)$$

Chi phí này hợp lý khi chạy offline trên GPU để tạo artifact, nhưng không phù hợp nếu mỗi video upload đều phải chạy full captioning model. Vì vậy, SnapUGC-LightKD chỉ học từ đặc trưng caption trong huấn luyện thông qua loss hallucination.

3.4.4 Nguyên tắc thiết kế rút ra

Từ các phân tích trên, luận văn rút ra ba nguyên tắc thiết kế:

1. **Không đưa backbone lớn vào suy luận Student:** các nhánh ResNet3D và mPLUG-2 được chuyển thành tín hiệu huấn luyện thay vì thành đầu vào bắt buộc.
2. **Giữ chuỗi thời gian ngắn:** Student xử lý chuỗi clip-level feature thay vì frame/patch-level raw token.
3. **Ưu tiên chất lọc hơn mở rộng đầu vào thô:** nếu thông tin đã được Teacher nén thành hidden state hoặc attention, Student nên học trực tiếp từ các tín hiệu đó thay vì nhận thêm đặc trưng thủ công nhiều.

3.5 Liên hệ giữa các nền tảng và thiết kế SnapUGC-LightKD

Các nền tảng trong chương này có thể được xem như ba lớp tri thức xếp chồng. Lớp thứ nhất là *cơ chế mô hình hóa*: Transformer và attention cung cấp công cụ học quan hệ trong chuỗi. Lớp thứ hai là *giao diện artifact*: các backbone Teacher tạo đặc trưng giàu ngữ nghĩa nhưng được xem như nguồn tham chiếu offline. Lớp thứ ba là *cơ chế chuyển giao*: KD, hidden alignment, attention transfer, ranking và LUPI cho phép Student học lại những phần quan trọng của Teacher.

Mối quan hệ này có thể được viết khái quát:

$$\underbrace{V, Meta}_{\text{dữ liệu thô}} \xrightarrow{\text{backbones}} \underbrace{F_T, A_T, \hat{y}_T}_{\text{tri thức Teacher}} \xrightarrow{\text{distillation}} \underbrace{f_S(X_{\text{deploy}})}_{\text{Student triển khai được}}. \quad (3.40)$$

Điểm then chốt là Student không cố tái tạo toàn bộ Teacher. Thay vào đó, Student học một ánh xạ đủ tốt từ giao diện triển khai được X_{deploy} tới ECR, dưới sự điều hướng của các tín hiệu Teacher. Điều này làm cho SnapUGC-LightKD khác với hai hướng cực đoan: một là chạy Teacher đầy đủ ở suy luận, hai là bỏ Teacher và huấn luyện Student nhỏ chỉ bằng nhân cứng.

Kết thúc chương, có thể thấy rằng SnapUGC-LightKD không phải một tập hợp rời rạc của nhiều mẹo kỹ thuật. Mỗi thành phần trong phương pháp đều có nguồn gốc từ một nền tảng lý thuyết đã được kiểm chứng, nhưng được điều chỉnh cho bài toán ECR hồi quy đa phương thức và ràng buộc triển khai nhẹ.

3.5.1 Tổng kết chương

Chương này đã trình bày ba khối nền tảng của luận văn. Transformer cung cấp cơ chế mô hình hóa chuỗi và attention theo thời gian. Giao diện

Bảng 3.2: Liên hệ giữa nền tảng lý thuyết và thành phần trong SnapUGC-LightKD

Nền tảng	Khái niệm chính	Hiện thực trong đề tài
Transformer	Self-attention, positional encoding	Temporal encoder của Student
Artifact Teacher	Feature stack đa phương thức offline	Đầu vào rút gọn, nhãn mềm, hidden, attention và đặc trưng đặc quyền
CLIP/Lite Action	Frontend mở rộng có thể triển khai	Bổ sung tín hiệu thị giác/chuyển động nhẹ ở cấu hình tốt nhất
Hinton KD	Soft target	Loss $\mathcal{L}_{soft_ECR}$
FitNets/AT	Hidden và attention alignment	Loss hidden và attention theo clip
RKD/LUPI	Quan hệ mẫu và thông tin đặc quyền	Ranking loss và hallucination head

artifact giải thích Teacher cung cấp những tín hiệu nào cho Student, đồng thời làm rõ artifact nào chỉ dùng trong huấn luyện. Knowledge Distillation cung cấp khung lý thuyết để chuyển giao tri thức từ Teacher sang Student, bao gồm tri thức đầu ra, tri thức biểu diễn, tri thức chú ý, quan hệ thứ hạng và thông tin đặc quyền. Trên cơ sở đó, Chương 4 sẽ mô tả chi tiết thiết kế SnapUGC-LightKD.

Chương 4


Phương pháp đề xuất

Chương này trình bày thiết kế chi tiết của SnapUGC-LightKD, một hệ thống chất lọc tri thức đa tầng cho bài toán dự đoán ECR của video ngắn. Khác với Chương 3, nơi các khái niệm nền tảng được trình bày độc lập, chương này mô tả cách các thành phần đó được kết hợp thành một pipeline hoàn chỉnh: Teacher đa phương thức tạo tín hiệu giám sát giàu thông tin, Student triển khai được học từ các tín hiệu đó, và hệ mất mát đa nhiệm điều phối quá trình chuyển giao tri thức.

4.1 Tổng quan thiết kế hệ thống

Mục tiêu thiết kế của SnapUGC-LightKD là đạt cân bằng giữa hiệu suất dự đoán ECR và khả năng triển khai. Teacher SnapUGC đầy đủ có khả năng quan sát nhiều modality, nhưng yêu cầu nhiều backbone lớn. Student phải nhẹ hơn và chỉ sử dụng các đầu vào có thể chuẩn bị với chi phí thấp hơn. Vì vậy, phương pháp được tổ chức thành hai pha:

- **Pha huấn luyện:** Teacher hoặc artifact từ Teacher cung cấp nhãn mềm, hidden state, attention, clip-level ECR và đặc trưng đặc quyền. Student được tối ưu bằng hệ loss đa nhiệm.
- **Pha suy luận:** Chỉ giữ lại Student deployable. Các nhánh Teacher và các mục tiêu đặc quyền không còn được sử dụng.



Hình 4.1: Tổng quan SnapUGC-LightKD: Teacher chỉ tham gia trong huấn luyện, Student được giữ lại khi suy luận.

4.2 Ký hiệu và dữ liệu đầu vào

Với một batch gồm B video, video thứ i có nhãn ECR thật $y_i \in [0, 1]$. Student nhận hai nhóm đầu vào chính. Nhóm thứ nhất là chuỗi đặc trưng video deployable, có thể chỉ là `frame_fusion_feature` ở mức diagnostic hoặc được mở rộng bằng CLIP/Lite Action ở cấu hình tốt nhất:

$$X_i^v = [x_{i,1}^v, x_{i,2}^v, \dots, x_{i,T_i}^v], \quad x_{i,t}^v \in \mathbb{R}^{d_{in}}. \quad (4.1)$$

Nhóm thứ hai là các embedding văn bản theo nguồn:

$$X_i^{txt} = [x_i^{sound}, x_i^{title}, x_i^{desc}], \quad x_i^m \in \mathbb{R}^{768}. \quad (4.2)$$

Do số clip hợp lệ có thể khác nhau, mô hình sử dụng mask:

$$M_i = [m_{i,1}, m_{i,2}, \dots, m_{i,T}], \quad m_{i,t} \in \{0, 1\}. \quad (4.3)$$

Teacher cung cấp các nhóm artifact sau:

$$\mathcal{A}_i^T = \{\hat{y}_{T,i}, \hat{c}_{T,i,1:T}, H_{T,i}^{temp}, H_{T,i}^{fuse}, X_{T,i}^{frame}, X_{T,i}^{text}, A_{T,i}^{mean}, A_{T,i}^{imp}, F_{T,i}^{act}, F_{T,i}^{cap}\}. \quad (4.4)$$


Trong đó $\hat{y}_{T,i}$ là ECR mềm cấp video, $\hat{c}_{T,i,t}$ là ECR theo clip, H_T^{temp} là hidden sau temporal Transformer, H_T^{fuse} là hidden ngay sau lớp hợp nhất đa phương thức, X_T^{frame} và X_T^{text} là artifact đầu vào rút gọn, A_T^{mean} và A_T^{imp} lần lượt là attention trung bình và attention importance theo thời gian, còn F_T^{act} và F_T^{cap} là đặc trưng đặc quyền từ action/caption. Các khóa lưu trữ cụ thể trong code được tóm tắt ở Bảng 4.2.

Bảng 4.1: Ký hiệu chính trong phương pháp SnapUGC-LightKD

Ký hiệu	Ý nghĩa
B	Kích thước batch huấn luyện
T	Số clip tối đa sau padding
X^v	Chuỗi đặc trưng video deployable $T \times d_{in}$
X^{txt}	Ba embedding văn bản sound/title/description
M	Mask clip hợp lệ
$\hat{y}_S, \hat{y}_T$	Dự đoán ECR của Student và Teacher
$\hat{c}_S, \hat{c}_T$	Dự đoán ECR theo clip của Student và Teacher
F_S, H_T	Hidden representation của Student và Teacher
X_T^{frame}, X_T^{text}	Artifact đầu vào rút gọn lấy từ Teacher: <code>frame_fusion_feature</code> , <code>text_tokens/text_pooled</code>
A_S, A_T^{imp}	Phân phối attention theo thời gian của Student và attention importance của Teacher
F_T^{act}, F_T^{cap}	Đặc trưng đặc quyền action và caption

4.3 Teacher tham chiếu và quá trình sinh artifact

Teacher tham chiếu là pipeline SnapUGC đa phương thức. Teacher quan sát video thông qua nhiều nhánh: đặc trưng thị giác khung hình, méo ảnh, hành động, caption, âm thanh và metadata văn bản. Trong triển khai thực nghiệm, việc chạy Teacher được thực hiện trước để sinh artifact, sau đó Student được huấn luyện trên artifact đã lưu. Cách làm này giúp tách chi phí Teacher khỏi vòng lặp huấn luyện Student và đảm bảo mọi cấu hình Student được so sánh trên cùng tín hiệu Teacher.



Hình 4.2: Kiến trúc Teacher SnapUGC đa phương thức. Teacher kết hợp các nhánh semantic/distortion từ khung hình, action/motion từ chuỗi clip, caption từ mPLUG-2, nhãn âm thanh và title/description qua text encoder và cross-attention trước khi hợp nhất để dự đoán ECR.

$$\text{TeacherForward}(V_i, \text{Meta}_i) \longrightarrow \mathcal{A}_i^T. \quad (4.5)$$

Trong code thực nghiệm, wrapper chỉ bật các hook xuất artifact khi chạy ở chế độ export; đường truyền tiền tạo ECR không bị thay đổi. Các

hook xuất được gắn tại những vị trí chính sau:

- `feat_12`, `feat_3_embed` và `feat4` lần lượt tạo artifact frame-fusion, action và caption.
- Vector sau `fc_merge123`, đầu ra sau `block1` và `self.out(out)` tạo hidden fusion, hidden temporal, ECR theo clip và ECR Teacher cấp video.
- Attention của block temporal được gom thành hai artifact; embedding văn bản được lưu dạng token và pooled.
- Caption sinh bởi mPLUG-2 được ghi thêm vào file JSONL đi kèm để đối chiếu định tính.

Bảng 4.2: Các artifact Teacher được xuất trong triển khai thực nghiệm

Artifact	Nguồn trong Teacher	Vai trò trong Student/KD
<code>teacher_ecr</code> <code>clip_ecr</code>	Đầu <code>self.out(out)</code> và trung bình theo clip	Soft target cấp video và giám sát ECR theo clip
<code>fusion_hidden</code>	Sau <code>fc_merge123</code>	Căn chỉnh hidden fusion của Student với Teacher
<code>temporal_hidden</code>	Sau block temporal self-attention	Căn chỉnh biểu diễn theo clip và tạo token upper-bound
<code>frame_fusion_feature</code>	<code>feat_12</code> từ nhánh semantic/distortion	Đầu vào video deployable chính của Student
<code>text_tokens</code> <code>text_pooled</code>	Embedding văn bản của text encoder	Đầu vào sound/title/description và token văn bản khi cần
<code>attention_mean</code> <code>attention_importance</code>	Attention map từ từng block	Attention transfer theo thời gian
<code>action_feature</code> <code>caption_feature</code>	ResNet3D action và mPLUG-2 caption feature	Mục tiêu privileged hallucination trong huấn luyện

Về mặt phương pháp, artifact Teacher có hai vai trò. Thứ nhất, nó cung cấp nhãn mềm để làm mượt nhãn ECR thật. Thứ hai, nó cung cấp cấu trúc biểu diễn trung gian mà Student không thể tự quan sát nếu chỉ nhìn đầu vào rỗng. Đây là lý do hệ thống không chỉ dùng một loss MSE giữa

ECR Student và Teacher, mà kết hợp nhiều nhóm loss ở các tầng khác nhau.

4.4 Kiến trúc Student deployable

4.4.1 Luồng video temporal Transformer

Student được triển khai theo hai mức cấu hình. Cấu hình diagnostic v35 chỉ dùng `frame_fusion_feature` nên $d_{in} = 1024$ và $d_s = 96$. Cấu hình tốt nhất bổ sung Lite Action và CLIP keyframe feature: nhánh Lite Action ghép `frame_fusion_feature` với đặc trưng chuyển động nhẹ thành $d_{in} = 2176$ và dùng $d_s = 256$, trong khi nhánh CLIP-hallucination giữ $d_s = 96$ nhưng thêm CLIP ViT-B/32 bằng cơ chế `clip_add`. Vì vậy, công thức dưới đây được viết theo dạng tổng quát $X^v \in \mathbb{R}^{T \times d_{in}}$:

$$H_v^{(0)} = \text{Dropout}(\text{GELU}(\text{LayerNorm}(X^v W_v + b_v))), \quad (4.6)$$

trong đó:

$$W_v \in \mathbb{R}^{d_{in} \times d_s}, \quad b_v \in \mathbb{R}^{d_s}. \quad (4.7)$$

Positional embedding được cộng vào chuỗi:

$$\tilde{H}_v^{(0)} = H_v^{(0)} + P_v, \quad P_v \in \mathbb{R}^{T \times d_s}. \quad (4.8)$$

Sau đó, chuỗi đi qua một temporal Transformer encoder:

$$H_v = \text{Transformer}_{time}(\tilde{H}_v^{(0)}, M). \quad (4.9)$$

Attention pooling tạo vector video cấp toàn cục:

$$a_t = \frac{\exp(w_a^\top \phi(H_{v,t}))}{\sum_{j=1}^T m_j \exp(w_a^\top \phi(H_{v,j}))}, \quad (4.10)$$

$$h_v = \sum_{t=1}^T a_t H_{v,t}. \quad (4.11)$$

Phân phối a_t chính là attention Student A_S dùng trong loss attention.

Với nhánh CLIP, embedding ảnh $X^{clip} \in \mathbb{R}^{T \times 512}$ được chiếu sang cùng không gian ảm và cộng vào token video trước temporal encoder:

$$\tilde{H}_{v,clip}^{(0)} = \tilde{H}_v^{(0)} + \text{LayerNorm}(X^{clip}W_{clip} + b_{clip}). \quad (4.12)$$

Cơ chế này giữ cấu trúc temporal Transformer không đổi nhưng bổ sung ngữ nghĩa thị giác cấp keyframe. Với nhánh Lite Action, đặc trưng chuyển động nhẹ được ghép trực tiếp vào X^v , giúp Student quan sát tín hiệu động học mà không cần chạy ResNet3D của Teacher.

4.4.2 Luồng văn bản và Source-specific text embedding

Student nhận ba nguồn văn bản: nhãn âm thanh, tiêu đề và mô tả. Nếu chỉ xem ba vector này như các token văn bản đồng nhất, attention pooling có thể trở nên gần như hoán vị bất biến: mô hình khó biết token nào đến từ title, token nào đến từ description, và token nào là nhãn âm thanh. Điều này đặc biệt nguy hiểm trong tập dữ liệu nhỏ vì mô hình có thể học các tương quan giả giữa giá trị embedding và nhãn ECR.

Để giải quyết, SnapUGC-LightKD cộng thêm embedding nguồn E_{source} sau khi chiếu văn bản:

$$h_m^{txt} = \text{TextProj}(x^m) + e_m^{source}, \quad m \in \{sound, title, desc\}. \quad (4.13)$$

Trong đó:

$$\text{TextProj}(x) = \text{Dropout}(\text{GELU}(\text{LayerNorm}(xW_t + b_t))), \quad (4.14)$$

$$W_t \in \mathbb{R}^{768 \times d_s}, \quad e_m^{source} \in \mathbb{R}^{d_s}. \quad (4.15)$$

Sau đó, text attention pooling tạo vector văn bản:

$$\beta_m = \frac{\exp(w_t^\top \phi(h_m^{txt}))}{\sum_r \exp(w_t^\top \phi(h_r^{txt}))}, \quad (4.16)$$

$$h_{txt} = \sum_m \beta_m h_m^{txt}. \quad (4.17)$$

Về mặt thống kê, source-specific embedding hoạt động như một biến chỉ báo nguồn. Nó giúp mô hình học các phân phối điều kiện khác nhau:

$$p(y \mid x^{sound}), \quad p(y \mid x^{title}), \quad p(y \mid x^{desc}), \quad (4.18)$$

thay vì ép cả ba nguồn vào một phân phối chung $p(y \mid x^{txt})$. Khi không có embedding nguồn, một embedding văn bản có độ lớn cao từ description có thể bị mô hình diễn giải giống như một nhãn âm thanh mạnh. Điều này làm tăng nguy cơ quá khớp vì Student học shortcut sai nguồn. Khi cộng e_m^{source} , không gian biểu diễn được tách thành các miền con mềm; attention pooling có thể học rằng sound-label thường phản ánh bối cảnh âm thanh, title thường phản ánh ý định thu hút, còn description thường chứa ngữ cảnh bổ sung nhưng cũng có thể nhiễu.

4.4.3 Fusion MLP và đầu dự đoán

Vector video h_v và vector văn bản h_{txt} được nối lại:

$$h_{cat} = [h_v; h_{txt}] \in \mathbb{R}^{2d_s}. \quad (4.19)$$

Fusion MLP sinh biểu diễn hợp nhất:

$$h_f = \text{MLP}_{fusion}(h_{cat}). \quad (4.20)$$


Đầu ECR cấp video dùng sigmoid để bảo đảm đầu ra nằm trong $[0, 1]$:

$$\hat{y}_S = \sigma(\text{MLP}_{ECR}(h_f)). \quad (4.21)$$

Ngoài ra, Student có đầu dự đoán ECR theo clip:

$$\hat{c}_{S,t} = \sigma(\text{MLP}_{clip}(H_{v,t})), \quad t = 1, 2, \dots, T. \quad (4.22)$$

Đầu clip không nhất thiết được dùng trực tiếp khi suy luận, nhưng rất quan trọng trong huấn luyện vì nó cung cấp giám sát cục bộ theo thời gian từ Teacher.



Hình 4.3: Kiến trúc Student deployable của SnapUGC-LightKD. Với v35, $d_{in} = 1024$ và $d_s = 96$; với cấu hình tốt nhất, đầu vào video có thể gồm **frame_fusion**, Lite Action và CLIP. Các nhánh KD nét đứt chỉ dùng trong huấn luyện.

4.5 Mạng ảo ảnh dựa trên LUPI

4.5.1 Động lực thiết kế

Teacher có quyền truy cập các đặc trưng đặc quyền như action feature từ ResNet3D và caption feature từ mPLUG-2. Student deployable không nhận trực tiếp các đặc trưng này ở thời điểm suy luận. Nếu bỏ qua hoàn

toàn, Student sẽ thiếu các tín hiệu quan trọng về chuyển động và ngữ nghĩa caption. Mạng ảo ảnh được thiết kế để giải quyết khoảng trống này trong pha huấn luyện: Student học dự đoán lại đặc trưng đặc quyền từ hidden state của chính nó.

4.5.2 Kiến trúc AdvancedHallucinationHead

Với hidden state theo clip $H_v \in \mathbb{R}^{T \times d_s}$, một AdvancedHallucinationHead nhận từng vector $H_{v,t}$ và sinh đặc trưng đặc quyền dự đoán. Kiến trúc gồm bốn phần:

1. Lớp chiếu vào từ d_s sang $2d_s$.
2. LayerNorm và GELU để ổn định thang đo và tăng phi tuyến.
3. Hai residual block nối tắt.
4. Lớp chiếu ra tới số chiều của đặc trưng đặc quyền.

Cụ thể, với input $h \in \mathbb{R}^{d_s}$:

$$z_0 = \text{GELU}(\text{LayerNorm}(W_{in}h + b_{in})), \quad W_{in} \in \mathbb{R}^{2d_s \times d_s}. \quad (4.23)$$

Một residual block được định nghĩa:

$$\text{ResBlock}(z) = z + W_2 \text{Dropout}(\text{GELU}(\text{LayerNorm}(W_1 z + b_1))) + b_2. \quad (4.24)$$

Hai block liên tiếp tạo biểu diễn:

$$z_1 = \text{ResBlock}_1(z_0), \quad z_2 = \text{ResBlock}_2(z_1). \quad (4.25)$$


Đầu action hallucination sinh vector 512 chiều:

$$\hat{F}_{S,t}^{act} = W_{act} z_2 + b_{act}, \quad \hat{F}_{S,t}^{act} \in \mathbb{R}^{512}. \quad (4.26)$$

Đầu caption hallucination sinh vector 1024 chiều:

$$\hat{F}_{S,t}^{cap} = W_{cap}z_2 + b_{cap}, \quad \hat{F}_{S,t}^{cap} \in \mathbb{R}^{1024}. \quad (4.27)$$

Hai đầu này không làm tăng chi phí suy luận nếu bị loại bỏ sau huấn luyện, nhưng trong quá trình học chúng buộc hidden state của Student chứa thông tin dự đoán được các modality đặc quyền.



Hình 4.4: Mạng ảo ảnh học tái tạo đặc trưng đặc quyền của Teacher từ hidden state của Student.

4.6 Hệ thống hàm mất mát đa nhiệm

Hệ loss của SnapUGC-LightKD được thiết kế theo nguyên tắc: mỗi thành phần loss chuyển giao một loại tri thức khác nhau. Các hệ số λ không chỉ là hệ số kỹ thuật, mà thể hiện mức độ tin cậy và độ ưu tiên của từng nguồn giám sát. Nếu λ quá lớn, một tín hiệu có thể lấn át các tín hiệu khác; nếu quá nhỏ, tri thức tương ứng không được Student học đủ.

4.6.1 Loss nhãn cứng

Loss nhãn cứng neo Student vào ECR thật:

$$\mathcal{L}_{hard} = \frac{1}{B} \sum_{i=1}^B (\hat{y}_{S,i} - y_i)^2. \quad (4.28)$$

Hệ số λ_{hard} biểu diễn mức độ tin vào nhãn quan sát. Giá trị này cần đủ lớn để mô hình không chỉ bắt chước Teacher, nhưng không nên quá lớn nếu nhãn thật chứa nhiều hành vi.

4.6.2 Loss ECR mềm từ Teacher

Soft ECR loss ép Student mô phỏng dự đoán cấp video của Teacher:

$$\mathcal{L}_{soft_ECR} = \frac{1}{B} \sum_{i=1}^B (\hat{y}_{S,i} - \hat{y}_{T,i})^2. \quad (4.29)$$

Hệ số λ_{soft} điều chỉnh lượng tri thức Teacher ở đầu ra cuối. Về mặt vật lý, đây là mức độ tin vào Teacher như một bộ lọc nhiễu cho nhãn ECR thật.

4.6.3 Loss ECR theo clip

Teacher cung cấp dự đoán ECR cục bộ theo clip. Với mask M , loss clip được tính trên các vị trí hợp lệ:

$$\mathcal{L}_{clip} = \frac{1}{\sum_{i=1}^B \sum_{t=1}^T m_{i,t}} \sum_{i=1}^B \sum_{t=1}^T m_{i,t} (\hat{c}_{S,i,t} - \hat{c}_{T,i,t})^2. \quad (4.30)$$

Hệ số λ_{clip} quyết định mức độ Student học cấu trúc thời gian cục bộ. Nếu λ_{clip} quá thấp, Student có thể chỉ học điểm cuối mà bỏ qua clip quan trọng; nếu quá cao, mô hình có thể quá tập trung vào nhiễu cục bộ.

4.6.4 Loss attention theo thời gian

Attention loss căn chỉnh phân phối chú ý theo clip giữa Student và Teacher:

$$\mathcal{L}_{attn} = \frac{1}{B} \sum_{i=1}^B \sum_{t=1}^T m_{i,t} A_{T,i,t} \log \frac{A_{T,i,t} + \epsilon}{A_{S,i,t} + \epsilon}. \quad (4.31)$$

Trong đó ϵ là hằng số nhỏ tránh logarit của 0. Hệ số λ_{attn} biểu diễn mức độ tin rằng Teacher biết đoạn nào của video quan trọng. Thành phần này đặc biệt có ý nghĩa khi video chứa một khoảnh khắc ngắn quyết định ECR.

4.6.5 Loss căn chỉnh hidden state

Để căn chỉnh không gian biểu diễn, Student dùng đầu chiếu g_θ đưa hidden của mình sang không gian Teacher:

$$\tilde{F}_{S,i}^{temp} = g_\theta(F_{S,i}^{temp}), \quad \tilde{F}_{S,i}^{fuse} = g_\theta(F_{S,i}^{fuse}). \quad (4.32)$$

Loss hidden dùng cosine distance:

$$\mathcal{L}_{hidden} = \frac{1}{B} \sum_{i=1}^B \left(1 - \frac{(\tilde{F}_{S,i}^{fuse})^\top F_{T,i}^{fuse}}{\|\tilde{F}_{S,i}^{fuse}\|_2 \|F_{T,i}^{fuse}\|_2} \right). \quad (4.33)$$

Hệ số λ_{hidden} điều khiển mức độ Student học không gian biểu diễn của Teacher, thay vì chỉ học đầu ra.

4.6.6 Loss quan hệ mẫu RKD

Relational KD bảo toàn quan hệ thứ hạng giữa các mẫu trong batch. Với Teacher score $\hat{y}_T$, quan hệ giữa hai mẫu là:

$$r_{ij}^T = \text{sign}(\hat{y}_{T,i} - \hat{y}_{T,j}). \quad (4.34)$$

Loss RKD dạng hinge được viết:

$$\mathcal{L}_{RKD} = \frac{2}{B(B-1)} \sum_{1 \leq i < j \leq B} \max(0, m - r_{ij}^T(\hat{y}_{S,i} - \hat{y}_{S,j})). \quad (4.35)$$

Trong đó m là margin thứ hạng. Hệ số λ_{RKD} phản ánh tầm quan trọng của tương quan thứ hạng. Khi mục tiêu đánh giá có SRCC, thành phần

này đóng vai trò cầu nối giữa tối ưu loss và metric.

4.6.7 Loss hallucination đặc quyền

Loss hallucination ép Student tái tạo đặc trưng action và caption của Teacher:

$$\mathcal{L}_{halluc} = \lambda_{act} \mathcal{D}(\hat{F}_S^{act}, F_T^{act}) + \lambda_{cap} \mathcal{D}(\hat{F}_S^{cap}, F_T^{cap}), \quad (4.36)$$

trong đó $\mathcal{D}$ có thể là cosine distance hoặc normalized MSE. Hai hệ số λ_{act} và λ_{cap} cho biết mức độ ưu tiên của thông tin chuyển động và thông tin caption. Nếu dữ liệu có nhiều video action-heavy, λ_{act} có thể đóng vai trò quan trọng hơn.

4.6.8 Tổng loss

Tổng loss đa nhiệm được viết:

$$\begin{aligned} \mathcal{L}_{total} = & \lambda_{hard} \mathcal{L}_{hard} + \lambda_{soft} \mathcal{L}_{soft_ECR} + \lambda_{clip} \mathcal{L}_{clip} + \lambda_{attn} \mathcal{L}_{attn} \\ & + \lambda_{hidden} \mathcal{L}_{hidden} + \lambda_{RKD} \mathcal{L}_{RKD} + \lambda_{halluc} \mathcal{L}_{halluc}. \end{aligned} \quad (4.37)$$

Về mặt tối ưu, các hệ số λ thực hiện ba chức năng: cân bằng thang đo gradient giữa các loss, điều chỉnh độ tin cậy của nguồn tri thức, và đóng vai trò regularization để tránh Student quá khớp vào một tín hiệu duy nhất.

4.7 Chiến lược huấn luyện đa giai đoạn

Do tổng loss gồm nhiều mục tiêu, việc bật tất cả thành phần với trọng số lớn ngay từ đầu có thể làm Student mất ổn định. SnapUGC-LightKD sử dụng chiến lược huấn luyện đa giai đoạn: Warm-up, Deep Alignment, Privileged Information và Fine-tuning. Giai đoạn đầu giúp mô hình học

Bảng 4.3: Ý nghĩa của các trọng số trong hàm mất mát đa nhiệm

Trọng số	Ý nghĩa thiết kế
λ_{hard}	Mức độ bám vào nhãn ECR thật; giữ mô hình không lệ thuộc hoàn toàn vào Teacher
λ_{soft}	Mức độ tin vào dự đoán mềm của Teacher như tín hiệu làm mượt nhiễu
λ_{clip}	Mức độ học cấu trúc đóng góp theo từng clip
λ_{attn}	Mức độ bắt chước vị trí chú ý quan trọng theo thời gian
λ_{hidden}	Mức độ căn chỉnh không gian biểu diễn trung gian
λ_{RKD}	Mức độ ưu tiên thứ hạng tương đối giữa video
λ_{halluc}	Mức độ khai thác thông tin đặc quyền action/caption trong huấn luyện

dự đoán cơ bản; giai đoạn sau mới tăng cường căn chỉnh sâu và thông tin đặc quyền.

```

1 # Inputs:
2 #   D: training set of videos and labels
3 #   Teacher: full multimodal teacher or cached teacher artifacts
4 #   Student: deployable SnapUGC-LightKD student
5 #   AdamW: optimizer for student parameters
6
7 for epoch in range(E):
8     phase = schedule(epoch)
9     set_loss_weights(lambda, phase)
10
11     for batch in D:
12         video, metadata, y_true, mask = batch
13
14         # Teacher forward can be online or loaded from cached artifacts
15         with no_grad():
16             teacher_out = Teacher.forward(video, metadata)
17             y_T = teacher_out.soft_ecr
18             clip_T = teacher_out.clip_ecr
19             hidden_T = teacher_out.hidden_states
20             attn_T = teacher_out.temporal_attention
21             act_T = teacher_out.action_feature
22             cap_T = teacher_out.caption_feature
23

```

```

24 # Student forward uses only deployable inputs
25 student_out = Student.forward(
26     deployable_video_features=batch.video_features,
27     optional_clip_features=batch.clip_features,
28     sound_title_desc_text=batch.text_embeddings,
29     clip_mask=mask
30 )
31 y_S      = student_out.ecr
32 clip_S   = student_out.clip_ecr
33 hidden_S = student_out.hidden_states
34 attn_S   = student_out.temporal_attention
35 act_S    = student_out.hallucinated_action
36 cap_S    = student_out.hallucinated_caption
37
38 # Multi-task distillation losses
39 L_hard   = mse(y_S, y_true)
40 L_soft   = mse(y_S, y_T)
41 L_clip   = masked_mse(clip_S, clip_T, mask)
42 L_attn   = kl_divergence(attn_T, attn_S, mask)
43 L_RKD    = pairwise_rank_loss(y_S, y_T)
44 L_hallu  = repr_loss(act_S, act_T) + repr_loss(cap_S, cap_T)
45
46 L_total = lambda_hard * L_hard \
47           + lambda_soft * L_soft \
48           + lambda_clip * L_clip \
49           + lambda_attn * L_attn \
50           + lambda_RKD  * L_RKD  \
51           + lambda_hallu * L_hallu
52
53 AdamW.zero_grad()
54 L_total.backward()
55 clip_grad_norm_(Student.parameters())
56 AdamW.step()
57
58 evaluate(Student, validation_set)
59 save_best_checkpoint(Student)

```

Listing 4.1: Pseudocode chiến lược huấn luyện đa giai đoạn SnapUGC-LightKD

Bốn giai đoạn được hiểu như sau:

- **Warm-up:** ưu tiên $\mathcal{L}_{hard}$ và $\mathcal{L}_{soft_ECR}$ để Student học thang đo ECR ổn định.

- **Deep Alignment:** tăng λ_{clip} , λ_{attn} và λ_{hidden} để căn chỉnh biểu diễn theo thời gian.
- **Privileged Information:** kích hoạt mạnh hơn λ_{halluc} để học action/caption feature đặc quyền.
- **Fine-tuning:** giảm learning rate và tập trung tối ưu tương quan PLCC/SRCC trên validation.

4.8 Phân tích độ phức tạp và triển khai hệ thống

Một yêu cầu quan trọng của SnapUGC-LightKD là giữ pha suy luận đủ nhẹ. Vì vậy, ngoài độ chính xác, thiết kế hệ thống cần được đánh giá theo số phép toán và bộ nhớ trung gian. Với Student, chi phí lớn nhất nằm ở temporal Transformer và các MLP chiều đặc trưng.

Với chuỗi clip dài T và hidden dimension d_s , chi phí attention xấp xỉ:

$$\mathcal{O}_{Student-attn} = \mathcal{O}(T^2 d_s). \quad (4.38)$$

Do d_s nằm trong khoảng 96–256 và T là số clip đã rút gọn, chi phí này nhỏ hơn nhiều so với việc chạy attention trên patch ảnh hoặc token video thô. Chi phí projection video là:

$$\mathcal{O}_{video-proj} = \mathcal{O}(T \cdot d_{in} \cdot d_s). \quad (4.39)$$

Chi phí projection văn bản là:

$$\mathcal{O}_{text-proj} = \mathcal{O}(3 \cdot 768 \cdot d_s). \quad (4.40)$$

Các đầu hallucination có chi phí trong huấn luyện nhưng có thể loại bỏ khi suy luận. Do đó, chi phí suy luận thực tế không phụ thuộc vào chiều 512

của action feature Teacher hay chiều 1024 của caption feature Teacher. Cấu hình tốt nhất vẫn cần các extractor deployable nhẹ hơn như CLIP ViT-B/32 keyframe và MobileNetV3-Small Lite Action, nhưng tránh hai thành phần nặng nhất của Teacher là mPLUG-2 và ResNet3D.

4.8.1 Tổ chức artifact và tính tái lập

Trong thực nghiệm, Teacher artifact được xem như một tập dữ liệu trung gian. Mỗi video tương ứng với một bản ghi gồm input deployable và tín hiệu Teacher. Cách tổ chức này có ba lợi ích:

1. **Tái lập:** mọi cấu hình Student đọc cùng artifact, loại bỏ biến thiên do Teacher inference.
2. **Hiệu quả:** không cần chạy Teacher trong mỗi epoch Student.
3. **Chẩn đoán:** có thể huấn luyện upper-bound compressed Student để đo lường thông tin nằm trong hidden Teacher.

Về mặt ký hiệu, artifact dataset có thể được viết:

$$\mathcal{D}_{artifact} = \{X_i^v, X_i^{txt}, M_i, y_i, \mathcal{A}_i^T\}_{i=1}^N. \quad (4.41)$$

Trong đó $\mathcal{A}_i^T$ là tập tín hiệu Teacher đã mô tả ở Mục 4.2.

4.9 Ổn định tối ưu và cân bằng gradient

Một khó khăn khi huấn luyện multi-task loss là các thành phần loss có thang đo khác nhau. Ví dụ, MSE của ECR nằm trong khoảng nhỏ vì $y \in [0, 1]$, trong khi hidden alignment hoặc attention KL có thể có độ lớn khác. Nếu không cân bằng, gradient tổng có thể bị chi phối bởi một thành phần:

$$\nabla_{\theta} \mathcal{L}_{total} = \sum_k \lambda_k \nabla_{\theta} \mathcal{L}_k. \quad (4.42)$$

Mục tiêu của chọn λ_k là làm cho các vector gradient không triệt tiêu hoặc lẫn át nhau. Một cách nhìn trực giác là xét chuẩn gradient:

$$g_k = \|\lambda_k \nabla_{\theta} \mathcal{L}_k\|_2. \quad (4.43)$$

Nếu g_{attn} quá lớn, mô hình có thể chỉ học attention mà bỏ qua ECR. Nếu g_{soft} quá nhỏ, tín hiệu Teacher cấp video không đủ tác động. Vì vậy, quá trình huấn luyện đa giai đoạn trong Mục 4.7 cũng là một cơ chế cân bằng gradient theo thời gian.

4.9.1 Vai trò của AdamW và weight decay

AdamW tách weight decay khỏi cập nhật moment thích nghi. Với gradient g_t , AdamW cập nhật tham số theo:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad (4.44)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \quad (4.45)$$

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon} - \eta \lambda_{wd} \theta_t. \quad (4.46)$$

Trong bài toán này, AdamW phù hợp vì các nhóm tham số có thang gradient khác nhau: projection video, text projection, Transformer, fusion MLP và hallucination heads. Weight decay đóng vai trò regularization, đặc biệt quan trọng khi tập huấn luyện chỉ gồm 4.000 video.

4.10 Pseudocode suy luận triển khai

Để phân biệt rõ pha huấn luyện và pha suy luận, dưới đây là mã giả suy luận sau khi đã huấn luyện xong Student.

```

1 # Input: deployable features only
2 #   deployable_video_features: T x d_in
3 #   optional_clip_features: T x 512, if using clip_add branch

```

```

4 # sound/title/description embeddings: 3 x 768
5 # clip_mask: T
6 # Output:
7 # predicted ECR score in [0, 1]
8
9 load Student checkpoint
10 Student.eval()
11
12 with no_grad():
13     video_tokens = video_projection(deployable_video_features)
14     if optional_clip_features is not None:
15         video_tokens = video_tokens + clip_projection(
optional_clip_features)
16     video_tokens = video_tokens + positional_embedding
17     temporal_hidden = temporal_transformer(video_tokens, clip_mask)
18     video_hidden, temporal_attention = attention_pool(temporal_hidden)
19
20     text_tokens = text_projection(sound_title_description)
21     text_tokens = text_tokens + source_type_embedding
22     text_hidden, text_attention = text_attention_pool(text_tokens)
23
24     fused_hidden = fusion_mlp(concat(video_hidden, text_hidden))
25     ecr_score = sigmoid(ecr_head(fused_hidden))
26
27 return ecr_score

```

Listing 4.2: Pseudocode suy luận deployable của SnapUGC-LightKD

Mã giả này cho thấy không có lời gọi Teacher, ResNet3D hoặc mPLUG-2 trong suy luận. Với cấu hình Edge Ensemble, hai Student deployable được chạy độc lập rồi lấy trung bình trọng số 0.50/0.50. Đây là tiêu chí quan trọng để phân loại mô hình là deployable.

4.11 Suy luận triển khai

Khi suy luận, Student không cần Teacher, không cần action feature ResNet3D và không cần caption feature mPLUG-2. Luồng suy luận chỉ gồm:

$$(X^v, X^{clip}, X^{lite}, X^{txt}, M) \longrightarrow \text{Student} \longrightarrow \hat{y}_S, \quad (4.47)$$

trong đó X^{clip} và X^{lite} chỉ xuất hiện ở các cấu hình mở rộng. Các đầu hallucination và projection KD có thể bị bỏ qua. Điều này làm rõ bản chất của phương pháp: chi phí Teacher được chuyển sang pha huấn luyện, còn pha suy luận giữ lại một mô hình gọn nhẹ.

4.12 Tổng kết chương

Chương này đã mô tả SnapUGC-LightKD như một hệ thống thiết kế hoàn chỉnh. Student được xây dựng từ temporal Transformer nhẹ, source-specific text embedding, fusion MLP và các nhánh deployable mở rộng như CLIP/Lite Action ở cấu hình tốt nhất. Teacher cung cấp nhiều tín hiệu chất lọc: ECR mềm, ECR theo clip, hidden state, attention, quan hệ thứ hạng và đặc trưng đặc quyền. Hệ loss đa nhiệm điều phối các nguồn tri thức này bằng các hệ số λ có ý nghĩa rõ ràng. Chương 5 sẽ đánh giá thực nghiệm các quyết định thiết kế này và phân tích giới hạn thông tin đầu vào.

Chương 5

Thực nghiệm và kết quả

Chương này trình bày thiết lập thực nghiệm, kết quả định lượng và phân tích chuyên sâu cho SnapUGC-LightKD. Khác với việc chỉ báo cáo điểm số cuối cùng, chương này tập trung giải thích vì sao Student cải thiện nhờ chất lọc tri thức, vì sao vẫn tồn tại khoảng cách với Teacher, và vì sao một số hướng bổ sung đặc trưng tưởng như hữu ích lại làm giảm hiệu suất. Các phân tích này đóng vai trò kiểm chứng các giả thuyết thiết kế đã nêu ở Chương 4.


5.1 Tập dữ liệu và giao thức đánh giá

5.1.1 Tập dữ liệu SnapUGC

Tập dữ liệu SnapUGC [1] được xây dựng cho bài toán dự đoán mức độ thu hút của video ngắn. Trong luận văn, toàn bộ thực nghiệm Student được thực hiện trên tập con cân bằng gồm 5.000 video. Mỗi mẫu có nhãn ECR nằm trong khoảng $[0, 1]$:

$$\mathcal{D} = \{(V_i, Meta_i, y_i)\}_{i=1}^{5000}, \quad y_i \in [0, 1]. \quad (5.1)$$

Trong đó V_i là video, $Meta_i$ gồm các thông tin như tiêu đề/mô tả và y_i là nhãn ECR thật.



Hình 5.1: Một số khung hình mẫu trong tập dữ liệu SnapUGC. Các mẫu bao phủ nhiều bối cảnh video ngắn như đồ ăn, thể thao, phương tiện, động vật, giải trí và cảnh tự nhiên, cho thấy bài toán ECR phụ thuộc đồng thời vào nội dung thị giác, chuyển động, âm thanh và metadata văn bản.

5.1.2 Giao thức chia dữ liệu

Để tránh rò rỉ dữ liệu, tất cả các cấu hình Student sử dụng cùng một cách chia dữ liệu cố định:

$$\mathcal{D}_{\text{train}} = 4000, \quad \mathcal{D}_{\text{val}} = 1000. \quad (5.2)$$

Quá trình chia dữ liệu sử dụng seed 42. Việc cố định cách chia đặc biệt quan trọng vì khác biệt điểm số giữa các cấu hình Student có thể nhỏ; nếu cách chia thay đổi, nhiều lấy mẫu có thể che lấp đóng góp của từng thành phần hàm mất mát.

5.2 Độ đo đánh giá

Ba độ đo chính được sử dụng gồm PLCC, SRCC và Final Score. PLCC đo tương quan tuyến tính giữa dự đoán và nhãn:

$$\text{PLCC} = \frac{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y})^2}}. \quad (5.3)$$

SRCC đo tương quan thứ hạng:

$$\text{SRCC} = 1 - \frac{6 \sum_{i=1}^N d_i^2}{N(N^2 - 1)}, \quad (5.4)$$

trong đó d_i là sai khác thứ hạng giữa dự đoán và nhãn. Final Score được tính theo tổ hợp:

$$\text{Final} = 0.6 \times \text{SRCC} + 0.4 \times \text{PLCC}. \quad (5.5)$$

Cách định nghĩa này khiến SRCC có trọng số cao hơn PLCC, phản ánh tầm quan trọng của xếp hạng video trong bối cảnh gợi ý nội dung.

5.3 Thiết lập thực nghiệm

5.3.1 Artifact của Teacher

Teacher SnapUGC được chạy để tạo các nhóm artifact: ECR mềm và ECR theo clip; hidden state `fusion_hidden/temporal_hidden`; đầu vào rút gọn `frame_fusion_feature` và `text_tokens/text_pooled`; attention `attention_mean/attention_importance`; cùng đặc trưng đặc quyền `action_feature/caption_feature`. Các artifact này được cố định trong toàn bộ thực nghiệm Student. Nhờ đó, sự khác biệt giữa các cấu hình Student phản ánh thay đổi trong kiến trúc hoặc hàm mất mát, thay vì

thay đổi từ phía Teacher.

5.3.2 Cấu hình Student chính

Các thí nghiệm trong chương này phân biệt hai mốc. Mốc v35 là cấu hình chuẩn đoán ban đầu, dùng để kiểm tra hiệu quả của KD trên giao diện `frame_fusion+text` rút gọn. Kết quả tốt nhất hiện tại của SnapUGC-LightKD là cấu hình có thể triển khai mở rộng, gồm hai nhánh Student được ensemble: nhánh Lite Action và nhánh CLIP-hallucination. Các siêu tham số chính được tóm tắt ở Bảng 5.1.

Bảng 5.1: Cấu hình thực nghiệm chính của SnapUGC-LightKD tốt nhất

Thuộc tính	Giá trị
Preset đầu vào	<code>visual_text_sound</code> mở rộng bằng CLIP và Lite Action
Đầu vào video	<code>frame_fusion_feature</code> $T \times 1024$, Lite Action $T \times 1152$, CLIP ViT-B/32 keyframe embedding $T \times 512$
Đầu vào văn bản	Embedding của sound-label, title và description, mỗi nguồn 768 chiều
Hidden dimension	256 cho nhánh Lite Action; 96 cho nhánh CLIP-hallucination
Temporal encoder	3 tầng Transformer, 8 head ở nhánh Lite Action; 1 tầng, 4 head ở nhánh CLIP-hallucination
Dropout	0.25 ở cấu hình tốt nhất
Optimizer	AdamW, learning rate 5×10^{-4} , weight decay 0.02 ở nhánh CLIP-hallucination
Batch size	32 huấn luyện, 128 đánh giá
Số epoch	100 cho cấu hình CLIP-hallucination; checkpoint tốt nhất được chọn trên tập validation

5.4 Kết quả thực nghiệm chính

Bảng 5.2 so sánh Teacher, baseline Student, các mốc Student KD và upper-bound compressed Student. Upper-bound compressed Student không phải cấu hình có thể triển khai; mô hình này nhận token nén trực tiếp từ trạng thái nội bộ Teacher, nên được dùng để chẩn đoán giới hạn thông tin. Trong các cấu hình có thể triển khai, kết quả cao nhất hiện tại là Edge Ensemble với Final Score 0.6330.

Bảng 5.2: Kết quả chính trên split kiểm định 1.000 video SnapUGC

Mô hình	Đầu vào	PLCC	SRCC	Final
Teacher SnapUGC	Toàn bộ stack đa phương thức	0.7103	0.6995	0.7038
Baseline Student	Frame fusion + CLIP + text	0.5629	0.5569	0.5593
Student KD chẩn đoán v35	Frame fusion + text + sound	0.6070	0.5999	0.6027
Best single Student KD	Frame fusion + CLIP/Lite Action + text	–	–	0.6290
SnapUGC-LightKD Edge Ensemble	Frame fusion + CLIP + Lite Action + text	0.6372	0.6302	0.6330
Upper-bound compressed	Teacher internal tokens	0.7007	0.6907	0.6947

SnapUGC-LightKD Edge Ensemble cải thiện Final Score từ 0.5593 lên 0.6330, tương ứng mức tăng:

$$\Delta_{KD} = 0.6330 - 0.5593 = 0.0737. \quad (5.6)$$

Điều này xác nhận rằng với giao diện đầu vào có thể triển khai, giàu thông tin hơn nhưng vẫn tránh các backbone nặng của Teacher, tri thức Teacher

giúp Student khai thác dữ liệu hiệu quả hơn so với huấn luyện chỉ bằng nhãn cứng. Mốc 0.6027 vẫn được giữ trong các phân tích chẩn đoán vì nó cô lập tác động của KD trên giao diện `frame_fusion+text` ban đầu; tuy nhiên đây không còn là kết quả tốt nhất của hệ thống.

5.5 Nghiên cứu lược bỏ thành phần

Bảng 5.3 trình bày đóng góp của các nhóm hàm mất mát trên chuỗi cấu hình Student KD. Các con số thể hiện xu hướng chính: logit/clip KD tạo bước nhảy đầu tiên, sau đó các tín hiệu biểu diễn, attention, ranking và hallucination tiếp tục cải thiện hiệu suất.

Bảng 5.3: Ablation study của các nhóm mất mát chất lọc

Tier	Thành phần huấn luyện	Final	Tăng
0	Chỉ dùng <code>hard_ecr</code> baseline	0.5243	—
1	Tier 0 + <code>soft_ecr</code> + <code>clip_ecr</code>	0.5732	+0.0489
2	Tier 1 + hidden alignment và attention KD	0.6027	+0.0295
3	Tier 2 + pairwise/listwise ranking KD	0.6127	+0.0100
4	Tier 3 + action/caption hallucination	0.6285	+0.0158

Kết quả cho thấy phần lớn cải thiện đến từ việc chuyển từ nhãn cứng sang nhãn mềm và clip-level KD. Điều này phù hợp với bản chất của ECR: nhãn thật có thể nhiễu do yếu tố phân phối nền tảng, trong khi Teacher đã tích hợp nhiều modality nên đóng vai trò bộ làm mượt. Các tín hiệu hidden, attention và ranking sau đó giúp Student học cấu trúc biểu diễn sâu hơn, đặc biệt cải thiện SRCC. Cuối cùng, hallucination của action/caption feature giúp Student tăng từ 0.6127 lên 0.6285 mà không cần chạy trực tiếp ResNet3D hoặc mPLUG-2 ở thời điểm suy luận.

5.6 Phân tích chẩn đoán và giới hạn thông tin đầu vào

5.6.1 Khoảng cách giữa Student có thể triển khai và upper-bound compressed Student

Khoảng cách quan trọng nhất trong kết quả tốt nhất hiện tại là:

$$\Delta_{\text{info}}^{\text{best}} = 0.6947 - 0.6330 = 0.0617. \quad (5.7)$$

Nếu xét riêng cấu hình chẩn đoán v35, khoảng cách tới upper-bound lớn hơn:

$$\Delta_{\text{info}}^{\text{v35}} = 0.6947 - 0.6027 = 0.0920. \quad (5.8)$$

Khoảng cách này không phải giữa Teacher và một Student bất kỳ, mà giữa các Student cùng họ kiến trúc nhưng khác giao diện đầu vào. Student có thể triển khai chỉ nhận X_{deploy} gồm video feature rút gọn, CLIP/Lite Action ở cấu hình tốt nhất và các embedding văn bản. Upper-bound compressed Student nhận X_{teacher} gồm token nén từ trạng thái nội bộ Teacher. Theo nguyên lý xử lý dữ liệu, nếu X_{deploy} là quan sát nghèo hơn, lượng thông tin về nhãn bị giới hạn:

$$I(Y; X_{\text{deploy}}) < I(Y; X_{\text{teacher}}). \quad (5.9)$$

Khi thông tin đầu vào không đủ, tăng độ phức tạp hàm f_{θ} không thể khôi phục thông tin đã mất:

$$\hat{Y} = f_{\theta}(X_{\text{deploy}}) \Rightarrow I(Y; \hat{Y}) \leq I(Y; X_{\text{deploy}}). \quad (5.10)$$

Do đó, upper-bound compressed Student đạt 0.6947 cho thấy kiến trúc Student có khả năng học nếu được cấp tín hiệu giàu hơn. Việc cải thiện từ 0.6027 lên 0.6330 sau khi bổ sung CLIP, Lite Action và ensemble cho

thấy một phần bottleneck đã được giảm, nhưng khoảng cách 0.0617 còn lại phản ánh thông tin nội bộ của Teacher vẫn chưa được tái tạo đầy đủ bởi giao diện có thể triển khai.

5.6.2 Vì sao tăng dung lượng Student lên 1.5M tham số làm giảm điểm

Thực nghiệm kiểm tra dung lượng trên giao diện v35 cho thấy Student lớn hơn, với hidden dimension 192, hai tầng Transformer và khoảng 1.5 triệu tham số ở phần đầu, chỉ đạt Final Score 0.5901, thấp hơn Student nhỏ 0.6027. Hiện tượng này có thể giải thích bằng phân rã sai số tổng quát:

$$\mathbb{E} \left[(Y - \hat{f}(X))^2 \right] = \text{Bias}^2 + \text{Variance} + \sigma_{\text{noise}}^2. \quad (5.11)$$

Khi mô hình quá nhỏ, bias cao. Khi tăng dung lượng, bias có thể giảm, nhưng variance tăng. Với tập huấn luyện chỉ 4.000 video và đầu vào có thông tin hữu hạn, việc tăng tham số làm mô hình dễ học các tương quan ngẫu nhiên trong split huấn luyện. Nói cách khác, mô hình lớn hơn có khả năng nội suy nhiều tốt hơn nhưng không làm tăng lượng thông tin có ích.

Có thể nhìn hiện tượng này qua tỷ lệ giữa dung lượng mô hình và số mẫu. Gọi $C(\theta)$ là độ phức tạp hiệu dụng của mô hình, một cận trực giác của khoảng cách tổng quát hóa có dạng:

$$\mathcal{G} \propto \sqrt{\frac{C(\theta)}{N}}. \quad (5.12)$$

Khi N cố định, tăng $C(\theta)$ làm khoảng cách tổng quát hóa tăng nếu dữ liệu không cung cấp thêm thông tin. Do đó, mô hình 1.5M tham số không giải quyết bottleneck của giao diện v35 mà còn khuếch đại nhiều, dẫn tới điểm kiểm định giảm. Ngược lại, mô hình lớn hơn trở nên có ích khi đi kèm đặc trưng CLIP/Lite Action giàu thông tin hơn, như kết quả Edge Ensemble 0.6330 cho thấy.

5.6.3 Bảng chẩn đoán đặc trưng đầu vào

Bảng 5.4 kiểm tra cả các đặc trưng thủ công trên mốc v35 và các cấu hình có thể triển khai tốt hơn dùng CLIP/Lite Action. Bảng này giải thích vì sao 0.6027 chỉ là mốc chẩn đoán, còn kết quả tốt nhất hiện tại là 0.6330.

Bảng 5.4: Hiệu suất của các mốc chẩn đoán và cấu hình có thể triển khai tốt nhất

Cấu hình	Đầu vào bổ sung	Baseline	KD Final
Base v35 chẩn đoán	–	0.5243	0.6027
OpenCV quality	18-d thủ công	0.5158	0.5843
Temporal motion	5-d thủ công	0.5257	0.5995
YAMNet logits	521-d thô	0.5096	0.5929
Student dung lượng lớn	cùng đầu vào với v35	–	0.5901
CLIP hallucination	CLIP ViT-B/32 keyframes	–	0.6285
Lite Action Student	MobileNetV3-Small motion	–	0.6290
Edge Ensemble	CLIP + Lite Action	–	0.6330
Ridge feature ceiling	đầu vào triển khai + quality features	–	0.4910
Upper-bound compressed	Teacher tokens	–	0.6947

5.6.4 Lời nguyền đa chiều và nhiễu đặc trưng thô

Việc bổ sung OpenCV quality features vào mốc v35 làm KD Final giảm từ 0.6027 xuống 0.5843. Về trực giác, blur, brightness hoặc noise có vẻ liên quan đến chất lượng video; tuy nhiên, chúng là tín hiệu cấp thấp và không nhất thiết tương quan mạnh với ECR. Khi thêm đặc trưng mới Z vào đầu vào X , mô hình thực chất học trên không gian $[X; Z]$. Nếu Z có thông tin điều kiện rất thấp:

$$I(Y; Z | X) \approx 0, \quad (5.13)$$

thì đặc trưng này không giúp giảm bias, nhưng vẫn làm tăng số chiều và số hướng mà mô hình có thể overfit.

Lời nguyền đa chiều có thể được diễn giải như sau. Với N mẫu trong không gian d chiều, mật độ mẫu hiệu dụng giảm rất nhanh khi d tăng.

Nếu muốn giữ mật độ phủ không gian ở mức tương đương, số mẫu cần tăng gần theo hàm mũ của d :

$$N_{\text{required}} \propto \epsilon^{-d}. \quad (5.14)$$

Do đó, thêm 521 chiều raw YAMNet logits làm không gian đầu vào mở rộng đáng kể, nhưng tập huấn luyện vẫn chỉ có 4.000 mẫu. Mạng nhỏ phải dành dung lượng để lọc nhiễu thay vì học quan hệ ECR có ích. Kết quả là cả baseline và KD đều giảm. Ngược lại, CLIP keyframe embedding và Lite Action không chỉ tăng chiều, mà còn bổ sung tín hiệu ngữ nghĩa và chuyển động có cấu trúc; vì vậy chúng giúp đẩy Student đơn lên khoảng 0.6285–0.6290 và ensemble lên 0.6330.

5.7 Phân tích định tính và nghiên cứu tình huống

Phần này trình bày ba kịch bản giả định dựa trên đặc điểm của dữ liệu SnapUGC. Các nghiên cứu tình huống này không thay thế đánh giá định lượng, nhưng giúp diễn giải trực quan vai trò của từng thành phần trong hệ thống.

5.7.1 Trường hợp 1: Video chuyển động mạnh nhưng thiếu đặc trưng hành động

Giả sử một video thể thao ngắn có cảnh trượt ván, cú nhảy hoặc va chạm bất ngờ. ECR cao vì người xem bị giữ lại bởi chuyển động nhanh và khoảnh khắc cao trào. Teacher quan sát đặc trưng ResNet3D nên nhận ra động học này. Student có thể triển khai chỉ nhận đặc trưng rút gọn; nếu đặc trưng đó không mã hóa đầy đủ chuyển động, Student có thể đánh giá thấp ECR.

Mạng hallucination giúp giảm lỗi này bằng cách ép hidden state của Student dự đoán lại action feature:

$$\hat{F}_S^{act} \approx F_T^{act}. \quad (5.15)$$

Dù Student không có ResNet3D khi suy luận, quá trình huấn luyện khiến không gian ẩn của nó nhạy hơn với các mẫu hình chuyển động gián tiếp có trong `frame_fusion_feature`.

5.7.2 Trường hợp 2: Video clickbait nhưng Teacher làm mượt nhiều

Một video có tiêu đề rất hấp dẫn nhưng nội dung thực tế không tương xứng có thể tạo ra tín hiệu metadata gây nhiễu. Nếu Student học trực tiếp từ nhãn cứng và metadata, mô hình có thể gán trọng số quá cao cho các từ khóa clickbait. Teacher đa phương thức quan sát cả nội dung video, âm thanh và caption nên có thể dự đoán ECR mềm thấp hơn mức mà title gợi ý.

Trong trường hợp này, soft ECR loss đóng vai trò thành phần điều chuẩn:

$$\mathcal{L}_{\text{soft}} = (\hat{y}_S - \hat{y}_T)^2. \quad (5.16)$$

Thành phần này kéo Student khỏi shortcut dựa trên tiêu đề và buộc mô hình cân bằng giữa metadata và tín hiệu video.

5.7.3 Trường hợp 3: Video có âm thanh/ngữ cảnh quan trọng

Một số video có hình ảnh tương đối đơn giản nhưng âm thanh hoặc mô tả cung cấp ngữ cảnh gây cười, bất ngờ hoặc cảm xúc. Nếu chỉ nhìn khung hình, mô hình có thể đánh giá video là bình thường. Nhãn âm thanh từ YAMNet được mã hóa như văn bản giúp Student nhận thêm ngữ cảnh.

Tuy nhiên, nếu trộn nhãn âm thanh với title/description mà không phân biệt nguồn, mô hình dễ học nhầm vai trò từng token.

Source-specific embedding giúp Student tách ba loại thông tin:

$$h_m^{\text{txt}} = \text{TextProj}(x^m) + e_m^{\text{source}}. \quad (5.17)$$

Nhờ đó, attention pooling có thể học rằng sound-label là tín hiệu bối cảnh âm thanh, còn title/description là tín hiệu ngữ nghĩa do người đăng cung cấp.

Bảng 5.5: Tóm tắt ba nghiên cứu tình huống định tính

Trường hợp	Hiện tượng	Thành phần phương pháp liên quan
Action-heavy	Chuyển động mạnh, Student dễ đánh giá thấp nếu thiếu action feature	Hallucination action head học từ ResNet3D feature
Clickbait	Ti-tle/description gây nhiễu so với nội dung thật	Soft ECR từ Teacher làm mượt shortcut metadata
Audio-context	Hình ảnh đơn giản nhưng âm thanh/ngữ cảnh quyết định ECR	Source-specific text embedding phân biệt sound/title/description

5.8 Phân tích thống kê bổ sung

5.8.1 Diễn giải đồng thời PLCC và SRCC

PLCC và SRCC phản ánh hai khía cạnh khác nhau. PLCC cao cho thấy mô hình dự đoán đúng thang giá trị tuyến tính; SRCC cao cho thấy mô hình sắp xếp thứ tự video đúng. Trong bài toán ECR, SRCC thường quan trọng hơn vì hệ thống gợi ý cần chọn video nào nên ưu tiên hiển thị. Một mô hình có thể có MSE thấp nhưng SRCC không cao nếu nó kéo mọi dự đoán về trung bình:

$$\hat{y}_i \approx \bar{y}, \quad \forall i. \quad (5.18)$$

Trường hợp này làm giảm sai số bình phương trên các mẫu trung bình nhưng không phân biệt tốt video hấp dẫn và kém hấp dẫn. Vì vậy, việc thêm ranking/listwise KD trong SnapUGC-LightKD nhằm tác động trực tiếp đến thứ tự xếp hạng:

$$y_i > y_j \Rightarrow \hat{y}_i > \hat{y}_j. \quad (5.19)$$

5.8.2 Sai số theo vùng nhãn

Một phân tích hữu ích là chia nhãn ECR thành ba vùng: thấp, trung bình và cao:

$$\mathcal{R}_{\text{low}} = [0, 0.33), \quad \mathcal{R}_{\text{mid}} = [0.33, 0.66), \quad \mathcal{R}_{\text{high}} = [0.66, 1]. \quad (5.20)$$

Các mô hình hồi quy nhỏ thường dự đoán tốt vùng trung bình nhưng khó ở hai vùng biên. Lý do là vùng biên có ít mẫu hơn và đòi hỏi tín hiệu ngữ nghĩa mạnh hơn. Đối với vùng ECR cao, mô hình cần phát hiện lý do video giữ chân người xem; đối với vùng ECR thấp, mô hình cần nhận ra yếu tố gây rời bỏ. Teacher đa phương thức giúp Student cải thiện ở hai vùng này bằng cách cung cấp soft target và attention theo clip.

5.8.3 Phân loại lỗi thường gặp

Bảng 5.6 tổng hợp các nhóm lỗi thường gặp và thành phần phương pháp có khả năng giảm lỗi.

Bảng 5.6: Phân loại lỗi định tính trong dự đoán ECR

Nhóm lỗi	Nguyên nhân khả dĩ	Thành phần giảm lỗi
Đánh giá thấp video chuyển động mạnh	Đầu vào triển khai thiếu đặc trưng động học chi tiết	Action hallucination, attention KD Soft ECR,
Đánh giá cao video clickbait	Metadata gây shortcut, nội dung thật yếu	source embedding
Không phân biệt video trung bình	Dự đoán co về giá trị trung bình, thiếu tín hiệu xếp hạng	RKD/listwise loss
Nhiều do đặc trưng thô	Đặc trưng bổ sung có thông tin điều kiện thấp	Điều chuẩn, chọn lọc đặc trưng
Sai ở video phụ thuộc âm thanh	Nhân âm thanh dạng text chưa đủ giàu	Bộ trích xuất âm thanh chuyên biệt trong tương lai

5.9 Độ tin cậy và giới hạn của thực nghiệm

5.9.1 Giới hạn do kích thước tập dữ liệu

Tập con 5.000 video đủ để đánh giá xu hướng chính nhưng vẫn tương đối nhỏ so với số chiều của các đặc trưng đa phương thức. Khi số mẫu hữu hạn, kết quả có thể chịu ảnh hưởng bởi split. Luận văn giảm rủi ro này bằng cách cố định seed và dùng cùng split cho tất cả cấu hình. Tuy

nhien, để khẳng định mạnh hơn, hướng tiếp theo nên đánh giá trên nhiều split hoặc tập kiểm thử ngoài miền.

5.9.2 Giới hạn do Teacher artifact

Student học từ artifact của Teacher, nên chất lượng tri thức phụ thuộc vào Teacher. Nếu Teacher sai một cách có hệ thống ở một nhóm video, Student có thể học lại sai lệch đó thông qua soft target. Về mặt tổng quát, nếu sai số Teacher là:

$$e_T = \hat{y}_T - y, \quad (5.21)$$

thì soft loss có thể truyền một phần sai số này sang Student. Vì vậy, loss nhân cứng $\mathcal{L}_{hard}$ vẫn cần được giữ lại để neo mô hình vào dữ liệu thật.

5.9.3 Giới hạn của nghiên cứu tình huống giả định

Các nghiên cứu tình huống ở Mục 5.7 là phân tích định tính giả định, không thay thế việc gán nhãn lỗi thủ công trên từng video. Chúng có vai trò minh họa cơ chế hoạt động của phương pháp. Một nghiên cứu tiếp theo có thể chọn các video cụ thể, trực quan hóa bản đồ attention và so sánh dự đoán của Teacher/Student để kiểm chứng trực tiếp các giả thuyết này.

5.10 Hàm ý thực tiễn cho triển khai

Kết quả thực nghiệm cho thấy nếu mục tiêu là triển khai thực tế, việc chỉ tăng kích thước Student không phải hướng tối ưu. Thay vào đó, cần ưu tiên ba hướng:

1. **Cải thiện frontend chi phí thấp:** xây dựng bộ trích xuất chuyển động nhẹ nhưng giàu thông tin hơn sai khác khung hình thô.

2. **Chọn lọc đặc trưng:** chỉ thêm đặc trưng nếu chứng minh được $I(Y; Z | X) > 0$ đủ lớn.
3. **Nén tri thức Teacher:** tiếp tục học token nén hoặc đặc trưng proxy có thể sinh bằng mô hình nhỏ.

Một tiêu chí triển khai tốt không chỉ là Final Score cao, mà là tỷ lệ giữa cải thiện điểm số và chi phí tăng thêm:

$$\rho = \frac{\Delta \text{Final}}{\Delta \text{Cost}}. \quad (5.22)$$

Theo tiêu chí này, KD đa tầng có lợi vì cải thiện điểm số mà không làm tăng chi phí suy luận đáng kể; ngược lại, thêm backbone lớn ở suy luận có thể tăng điểm nhưng làm ΔCost quá cao.

5.11 Độ nhạy siêu tham số và khuyến nghị tái lập

5.11.1 Độ nhạy của trọng số KD

Trong hệ hàm mất mát đa nhiệm, các trọng số λ quyết định mức độ ảnh hưởng của từng nguồn giám sát. Nếu λ_{soft} quá nhỏ, Student gần như trở về huấn luyện có giám sát thông thường. Nếu λ_{soft} quá lớn, Student có nguy cơ sao chép cả sai lệch của Teacher và bỏ qua nhân thật. Do đó, lựa chọn trọng số cần được hiểu như một bài toán cân bằng bias–variance:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{hard}} \mathcal{L}_{\text{hard}} + \lambda_{\text{soft}} \mathcal{L}_{\text{soft}} + \sum_k \lambda_k \mathcal{L}_k. \quad (5.23)$$

Về mặt thực nghiệm, nhóm hàm mất mát ở đầu ra thường nên được kích hoạt sớm vì chúng ổn định thang dự đoán ECR. Các hàm mất mát biểu diễn như hidden alignment và attention nên tăng dần sau khi Student đã học được dự đoán cơ bản. Nếu bật mạnh ngay từ đầu, Student có thể bị ép

đi vào không gian Teacher khi biểu diễn nội tại chưa ổn định, làm gradient dao động.

5.11.2 Độ nhạy của dropout và weight decay

Dropout và weight decay đóng vai trò quan trọng vì tập huấn luyện chỉ có 4.000 video. Với mô hình nhỏ, điều chuẩn quá mạnh có thể gây underfitting; với mô hình lớn hơn, điều chuẩn quá yếu làm overfitting tăng nhanh. Có thể mô tả trực giác này bằng hàm mục tiêu có điều chuẩn:

$$\min_{\theta} \mathcal{L}_{\text{train}}(\theta) + \lambda_{\text{wd}} \|\theta\|_2^2. \quad (5.24)$$

Khi λ_{wd} tăng, mô hình bị phạt nếu dùng trọng số lớn để học shortcut. Tuy nhiên, nếu λ_{wd} quá cao, mô hình không đủ linh hoạt để học quan hệ phi tuyến giữa video, văn bản và ECR. Các cấu hình tốt sử dụng dropout khoảng 0.22–0.25 và weight decay khoảng 0.01–0.02, phản ánh lựa chọn trung gian giữa hai cực này.

5.11.3 Độ nhạy của số tầng Transformer

Tăng số tầng Transformer giúp mở rộng phạm vi tiếp nhận biểu diễn và khả năng phi tuyến, nhưng cũng làm tăng số tham số và rủi ro quá khớp. Với chuỗi clip đã rút gọn, một tầng Transformer có thể đủ để học tương tác thời gian cơ bản. Khi tăng lên hai tầng trong mô hình lớn hơn, Final Score giảm xuống 0.5901. Điều này cho thấy nhiệm vụ không bị giới hạn bởi độ sâu của temporal encoder, mà bị giới hạn bởi thông tin trong đầu vào. Do đó, trong bối cảnh hiện tại, tăng chiều sâu không phải hướng cải thiện ưu tiên.

Bảng 5.7: Khuyến nghị điều chỉnh siêu tham số dựa trên phân tích thực nghiệm

Nhóm siêu tham số	Khuyến nghị
λ_{soft}	Bật sớm ở mức tương đối cao để làm mượt nhãn ECR, nhưng vẫn giữ λ_{hard} để neo vào nhãn thật
λ_{attn}	Tăng vừa phải sau warm-up; attention quá mạnh có thể làm mô hình bỏ qua tín hiệu giá trị ECR
λ_{RKD}	Hữu ích khi tối ưu SRCC; nên dùng cùng batch size đủ lớn để có nhiều cặp so sánh
Dropout	Giữ mức trung bình để hạn chế shortcut từ metadata và feature thô
Số tầng Transformer	Ưu tiên kiến trúc nông; tăng tầng chỉ hữu ích nếu đầu vào giàu thông tin hơn
Learning rate	Nên giảm dần ở cuối huấn luyện để ổn định checkpoint tốt nhất theo PLCC/SRCC

5.12 Kịch bản triển khai thực tế

5.12.1 Triển khai offline trong hệ thống kiểm duyệt nội dung

Một ứng dụng khả thi của SnapUGC-LightKD là chấm điểm ECR dự kiến cho video trước khi đưa vào hàng đợi phân phối. Trong kịch bản này, hệ thống có thể chạy Student trên artifact đã trích xuất sẵn. Điểm ECR dự đoán không quyết định trực tiếp video nào được hiển thị, nhưng đóng vai trò tín hiệu phụ cho bộ xếp hạng nội dung. Ưu điểm của Student nhẹ là có thể xử lý số lượng lớn video với chi phí thấp hơn Teacher.

5.12.2 Triển khai gần thời gian thực trên thiết bị biên

Trong kịch bản biên, yêu cầu quan trọng là độ trễ thấp. Student không chạy Teacher, không chạy mPLUG-2 và không chạy ResNet3D trong suy luận. Nếu các đặc trưng video/text đã được chuẩn bị bởi một frontend nhẹ, dự đoán ECR chỉ còn là lượt truyền tiến qua projection, temporal Transformer và fusion MLP:

$$\text{Latency}_{total} = \text{Latency}_{frontend} + \text{Latency}_{Student}. \quad (5.25)$$

Mục tiêu tương lai là giảm cả hai thành phần, đặc biệt là frontend. Kết quả chẩn đoán cho thấy thêm đặc trưng thô không đủ; frontend cần được học để tạo đặc trưng giàu thông tin hơn, chứ không chỉ tính các thống kê thủ công.

5.12.3 Triển khai như mô hình sàng lọc trước Teacher

Một kịch bản khác là dùng Student làm bộ lọc sơ cấp. Với một lượng lớn video, Student ước lượng nhanh ECR. Chỉ các video có độ bất định cao hoặc nằm gần ngưỡng quyết định mới được chuyển sang Teacher lớn. Khi đó, chi phí trung bình giảm:

$$\mathbb{E}[C] = (1 - p)C_S + p(C_S + C_T), \quad (5.26)$$

trong đó C_S là chi phí Student, C_T là chi phí Teacher và p là tỷ lệ mẫu cần Teacher xử lý lại. Nếu p nhỏ, hệ thống gần như giữ được lợi ích của Teacher ở các mẫu khó nhưng giảm đáng kể chi phí tổng.

5.13 Khuyến nghị cho các thí nghiệm tiếp theo

Từ các phân tích trên, có thể đề xuất bốn thí nghiệm tiếp theo. Thứ nhất, trực quan hóa attention theo clip để kiểm tra Student có tập trung vào cùng đoạn quan trọng với Teacher hay không. Thứ hai, đo sai số theo từng vùng ECR để xem mô hình cải thiện nhiều nhất ở vùng thấp, trung bình hay cao. Thứ ba, thay thế đặc trưng thủ công bằng một frontend chuyển động nhẹ được huấn luyện bằng hàm mất mát action hallucination. Thứ tư, đánh giá cross-split hoặc cross-domain để kiểm tra tính ổn định của mô hình khi phân phối video thay đổi.

Các thí nghiệm này không chỉ nhằm tăng điểm số, mà còn nhằm trả lời câu hỏi khoa học: phần tri thức nào của Teacher thực sự có thể chuyển sang Student có thể triển khai, và phần nào đòi hỏi đầu vào hoặc backbone giàu thông tin hơn. Trả lời câu hỏi này sẽ giúp định hướng phát triển các mô hình ECR thực tế, thay vì chỉ tối ưu một benchmark cố định.

5.14 Thảo luận tổng hợp

Kết quả thực nghiệm cho thấy ba kết luận chính. Thứ nhất, KD đa tầng cải thiện rõ rệt Student có thể triển khai, chứng minh Teacher chứa tri thức có thể chuyển giao. Thứ hai, upper-bound compressed Student gần Teacher cho thấy kiến trúc Student không phải rào cản chính; rào cản chính là thông tin đầu vào. Thứ ba, thêm đặc trưng thủ công không đảm bảo cải thiện, đặc biệt khi đặc trưng đó có số chiều cao, nhiều hoặc không tương quan điều kiện với ECR.

Những kết luận này định hướng phát triển tiếp theo: thay vì chỉ tăng tham số Student hoặc thêm đặc trưng thô, cần thiết kế các bộ trích xuất biên có độ trung thực cao hơn đối với chuyển động, caption và tín hiệu âm thanh, nhưng vẫn đủ nhẹ để triển khai thực tế.

5.15 Tổng kết chương

Chương này đã trình bày thiết lập thực nghiệm, kết quả chính, nghiên cứu lược bỏ thành phần, thí nghiệm chẩn đoán và phân tích định tính. Kết quả tốt nhất hiện tại của SnapUGC-LightKD là Edge Ensemble đạt PLCC 0.6372, SRCC 0.6302 và Final Score 0.6330, cải thiện +0.0737 so với baseline Student mở rộng 0.5593. Mốc 0.6027 được giữ như cấu hình chẩn đoán v35, cho thấy KD đa tầng có hiệu quả ngay cả khi chỉ dùng giao diện `frame_fusion+text` ban đầu. Phân tích bottleneck chỉ ra rằng khoảng cách còn lại 0.0617 tới upper-bound compressed Student xuất phát chủ yếu từ thiếu thông tin nội bộ của Teacher. Các nghiên cứu tình huống cho thấy vai trò bổ sung của hallucination network, soft ECR, CLIP/Lite Action và source-specific text embedding. Chương 6 sẽ tổng kết đóng góp và đề xuất hướng phát triển tương lai.

Chương 6

Kết luận và hướng phát triển

6.1 Tóm tắt đóng góp của đề tài

Trong khóa luận này, chúng tôi đã nghiên cứu và giải quyết thành công bài toán tối ưu hóa hiệu năng dự đoán chất lượng tương tác video ngắn trên mạng xã hội thông qua đề xuất hệ thống **SnapUGC-LightKD** (Lightweight Knowledge Distillation). Các đóng góp chính của đề tài bao gồm:

1. **Xây dựng thành công hệ thống chất lọc tri thức đa tầng:** Tích hợp các nhóm mất mát chất lọc tri thức quan trọng gồm logit matching, clip-level KD, FitNets, attention transfer, relational/listwise ranking và học đặc quyền LUPI.
2. **Thiết kế kiến trúc Student gọn nhẹ hiệu quả:** Đề xuất Student triển khai được dựa trên temporal Transformer nhẹ, source-specific text embedding và fusion MLP cho các đầu vào video, nhãn âm thanh, tiêu đề và mô tả.
3. **Đạt hiệu năng thực nghiệm vượt trội:** Cấu hình tốt nhất SnapUGC-LightKD Edge Ensemble đạt PLCC **0.6372**, SRCC **0.6302** và Final Score **0.6330** trên split kiểm định 1.000 video, cải thiện **+0.0737** so với baseline Student mở rộng. Thực nghiệm upper-

bound compressed Student đạt **0.6947**, gần Teacher **0.7038**, qua đó chỉ ra rõ giới hạn thông tin đầu vào của cấu hình triển khai được.

6.2 Hạn chế của đề xuất

Mặc dù đạt được những kết quả rất tích cực, hệ thống đề xuất vẫn tồn tại một số hạn chế cần được thảo luận khách quan:

- **Giới hạn thông tin (Information Bottleneck):** Như đã chứng minh qua các thực nghiệm chẩn đoán, khoảng cách hiệu suất còn lại giữa Student deployable và Teacher chủ yếu do sự thiếu hụt thông tin đầu vào tại thời điểm suy luận (đặc biệt là đặc trưng hành động ResNet3D và văn bản caption mPLUG-2). Mặc dù các tín hiệu KD giúp bù đắp một phần khoảng trống này, việc tái tạo đặc trưng chất lượng cao từ đầu vào rẻ vẫn là một bài toán đầy thách thức.
- **Chi phí tính toán của các bộ trích xuất đặc trưng biên (Backbone Extractors):** Mặc dù phần đầu phân loại của Student siêu nhẹ, việc chuẩn bị hoặc trích xuất các đặc trưng đầu vào video/văn bản tại thời điểm suy luận trên các dòng điện thoại di động phân khúc thấp vẫn sẽ gây ra những áp lực nhất định về thời lượng pin và nhiệt độ thiết bị.

6.3 Hướng phát triển tương lai

Từ những kết quả và hạn chế đã chỉ ra, chúng tôi đề xuất một số hướng nghiên cứu tiếp theo để hoàn thiện đề tài:

1. **Huấn luyện liên kết End-to-End:** Thay vì sử dụng các đặc trưng trích xuất đóng băng (frozen features), nghiên cứu tiếp theo có thể huấn luyện liên kết (joint training) các bộ trích xuất biên siêu nhẹ

và tối ưu hóa chúng trực tiếp trên nhãn ECR và các hàm mất mát chất lọc.

2. **Chắt lọc âm thanh trực tiếp (Direct Audio Distillation):** Thay vì sử dụng nhãn âm thanh YAMNet dạng văn bản, có thể nghiên cứu các bộ trích xuất phổ âm (spectrogram) siêu nhẹ dạng nơ-ron tích chập để Student trực tiếp học từ tín hiệu âm thanh gốc của video.
3. **Triển khai thực tế trên thiết bị di động (On-Device Deployment):** Chuyển đổi mô hình SnapUGC-LightKD sang các định dạng tối ưu hóa biên như ONNX hoặc CoreML để kiểm thử trực tiếp tốc độ khung hình (FPS) và mức độ tiêu thụ điện năng trên các hệ điều hành di động phổ biến (iOS, Android).

Tài liệu tham khảo

Tiếng Anh

- [1] Li, D., Gu, X., et al., “Snapugc: A user-generated content video engagement dataset,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024.
- [2] Hinton, G., Vinyals, O., and Dean, J., “Distilling the knowledge in a neural network,” in *NeurIPS Workshop on Deep Learning*, 2015.
- [3] Romero, A., Ballas, N., Kahou, S. E., Chassang, A., Gatta, C., and Bengio, Y., “Fitnets: Hints for thin deep nets,” in *International Conference on Learning Representations (ICLR)*, 2015.
- [4] Zagoruyko, S. and Komodakis, N., “Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer,” in *International Conference on Learning Representations (ICLR)*, 2017.
- [5] Park, W., Kim, D., Lu, Y., and Cho, M., “Relational knowledge distillation,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.
- [6] Arevalo, J., Solorio, T., Montes-y-Gómez, M., and González, F. A., “Gated multimodal units for information fusion,” in *Proceedings of the International Conference on Learning Representations (ICLR) Workshops*, 2017.

- [7] Radford, A. et al., “Learning transferable visual models from natural language supervision,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2021.
- [8] Xu, H., Ye, Q., et al., “Mplug-2: A modularized multi-modal foundation model across text, image and video,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2023.
- [9] Gou, J., Yu, B., Maybank, S. J., and Tao, D., “Knowledge distillation: A survey,” *International Journal of Computer Vision (IJCV)*, vol. 129, no. 6, pp. 1789–1819, 2021.
- [10] Wang, L. and Yoon, K.-J., “Knowledge distillation and student-teacher learning for visual intelligence: A review and new outlooks,” *IEEE Transactions on Pattern Analysis and Measurement (TPAMI)*, vol. 44, no. 6, pp. 3048–3068, 2022.
- [11] Fang, Y. et al., “Rankdvqa-mini: Knowledge distillation-driven deep video quality assessment,” in *Picture Coding Symposium (PCS)*, 2024.
- [12] Vapnik, V. and Shmelkin, R., “Learning with privileged information: A new paradigm,” *Neural Networks*, vol. 68, pp. 55–67, 2015.
- [13] Gupta, S., Hoffman, J., and Malik, J., “Cross modal distillation for supervision transfer,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [14] Bahdanau, D., Cho, K., and Bengio, Y., “Neural machine translation by jointly learning to align and translate,” *arXiv preprint arXiv:1409.0473*, 2014.
- [15] Luong, M.-T., Pham, H., and Manning, C. D., “Effective approaches to attention-based neural machine translation,” *arXiv preprint arXiv:1508.0402*, 2015.
- [16] Vaswani, A. et al., “Attention is all you need,” in *Proceedings of the Annual Conference on Neural Information Processing Systems (NeurIPS)*, 2017.

- [17] Tan, M. and Le, Q. V., “Efficientnetv2: Smaller models and faster training,” in *Proceedings of the International Conference on Machine Learning (ICML)*, 2021.
- [18] Tran, D., Wang, H., Torresani, L., Ray, J., LeCun, Y., and Paluri, M., “A closer look at spatiotemporal convolutions for action recognition,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [19] Dosovitskiy, A. et al., “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations (ICLR)*, 2021.